

基于多尺度本征模态排列熵和 SA-SVM 的轴承故障诊断研究^{*}

姚德臣^{1,2} 杨建伟^{1,2} 程晓卿³ 王兴⁴

(1.北京建筑大学机电与车辆工程学院 北京 100044;

2.北京建筑大学城市轨道交通车辆服役性能保障北京市重点实验室 北京 100044;

3.北京交通大学轨道交通控制与安全国家重点实验室北京 北京 100044;

4.太原科技大学计算机科学与技术学院 太原 030024)

摘要：针对轴承振动信号的非线性、非平稳性，提出一种基于多尺度本征模态排列熵和模拟退火优化支持向量机(Simulated annealing - support vector machine, SA-SVM)的列车轴承故障诊断方法。该方法首先对获取的轴承振动信息进行小波降噪处理，接着通过集合经验模态分解(Ensemble empirical mode decompose, EEMD)将去噪信号分解成若干个平稳的本征模态函数(Intrinsic mode function, IMF)，并提取多尺度本征模态排列熵作为 SVM 输入，在用样本训练 SVM 时，用 SA 对 SVM 的核函数进行优化，提高其分类准确率，最终实现智能化故障诊断。实验结果表明，基于多尺度本征模态排列熵和 SA-SVM 的列车轴承故障诊断方法能准确识别列车轴承故障类型，具有重要的实际工程应用价值。

关键词：EEMD；多尺度本征模态排列熵；SA-SVM；列车轴承；故障诊断

中图分类号：TH133.33；U279.34

Railway Rolling Bearing Fault Diagnosis Based on Muti-scale IMF Permutation Entropy and SA-SVM Classifier

YAO Dechen^{1,2} YANG Jianwei^{1,2} CHENG Xiaoqing³ WANG Xing⁴

(1.School of Machine-electricity and Automobile Engineering, Beijing University of Civil Engineering and Architecture, Beijing 100044;

2.Beijing Key Laboratory of Performance Guarantee on Urban Rail Transit Vehicles, Beijing University of Civil Engineering Architecture, Beijing 100044;

3.State Key Laboratory of Rail Traffic Control and Safety, Beijing Jiaotong University, Beijing 100044;

4.Department of Computer Science and Technology, Taiyuan University of Science and Technology, Taiyuan 030024)

Abstract: The vibration signals resulting from rolling bearings are non-linear and non-stationary, an approach for the fault diagnosis of railway rolling bearings using the multi-scale IMF permutation entropy and SA-SVM classifier is proposed. The signal is first denoised using wavelet de-noising (WD) as a pre-filter, which improves the subsequent decomposition into a number of intrinsic mode functions (IMFs) using ensemble empirical mode decompose (EEMD). Secondly, the multi-scale IMF permutation entropy are extracted as feature parameters. Finally, the extracted features are given input to SA-SVM for an automated fault diagnosis procedure. The results demonstrate its effectiveness for railway rolling bearings fault diagnosis. The fault diagnosis system has high application value in practical engineering.

Key word: EEMD; multi-scale IMF permutation entropy; SA-SVM; railway rolling bearing; fault diagnosis

0 前言^{*}

滚动轴承在轨道车辆运行中扮演着重要角色，

&TCD20150312)、国家重点研发计划课题“城市轨道交通系统安全保障技术”(2016YFB1200402)、轨道交通控制与安全国家重点实验室自主课题(RCS2010ZZ002)、建大英才培养计划课题的资助。xxxxxxx 收到初稿，xxxxxxx 收到修改稿

^{*} 国家自然科学基金资助项目(51605023)、长城学者培养计划项目(CIT

所处的工作条件通常温度较高,同时其结构内部的转动速度及工作载荷也相对较高,在其工作过程中,滚动轴承的诸多元件表面相互产生作用,易于在滚动轴承机械机构部位产生裂纹、断裂等缺陷,这些缺陷以结构振动加大、运转声音增加及运转阻力上升等形式表现出来,从而给城轨车辆的正常运行带来诸多问题,严重时可能导致后果恶劣的安全险情^[1]。因此,实现快速、准确的轴承工况监测与诊断对列车的正常运行具有重大意义。

列车轴承发生损伤性故障时,损伤点反复撞击与之接触的其他元件表面从而产生冲击性振动,使其振动信号往往是非线性非平稳的,且包含有多种频率成分,而且在其运行过程中,这些频率成分的幅值和频率又会受到冲击力的调制。因此,列车轴承故障振动信号是一种非线性非平稳的多分量调幅-调频信号。如果能有效增强振动信号的冲击特性,消除背景噪声的干扰,可以更为精确的提取故障特征,提升轴承故障的检测和诊断水平^[2]。

经验模态分解(Empirical mode decomposition, EMD)是基于三次样条曲线对信号进行自适应性的分解,能够对信号进行优异的时频聚焦,针对待分析数据的不同频带的特点进行处理^[3]。苏文胜等运用 EMD 降噪和谱峭度法对滚动轴承进行早期故障诊断^[4]。张志刚等采用 EMD 与滑动峰态算法提取了滚动轴承故障特征^[5]。徐卓飞等提出了一种融合经验模式分解和多元统计的轴承故障诊断方法,实现了对常见的三类轴承故障分类^[6]。但 EMD 存在模式混叠问题,为了抑制模式混叠, WU 等提出了总体平均经验模态分解(EEMD)的理论,该改进基于白噪声在尺度信号上的随机分布特性,通过多次平均,保障了 EMD 方法的模态分离效果^[7]。

排列熵作为 BANDT^[8]提出的一种检测时间序列随机性和动力学突变的方法,具有计算简单,抗噪能力强,计算速度快的特点。YAN^[9]等将其应用于旋转机械振动信号的特征提取,并将其与近似熵、Lempel-Ziv 复杂度进行了对比,结果表明,排列熵能够有效地检测和放大振动信号的动态变化,并且能够表征滚动轴承在不同状态下的工况特征。冯辅周利用排列熵进行了滚动轴承和减速箱数据的信号处理,获得了优异的结果^{[10][11]}。然而,与传统的基于单一尺度分析的非线性参数类似,排列熵只是检测时间序列在单一尺度上的随机性和动力学突变。机械系统中的成分较为繁杂,我们需要在考虑某一单个尺度内容的同时,基于系统整体性的量测标准进行多尺度的分析处理,从而保证振动信号的局部信息和整体信息的完整性^[12]。

SVM 属于一种智能故障诊断的理论,其基于机器学习概念,能够较为快速的得到待分类信号的整体最有解,同时,能够简单有效的实现处理方法的泛化移植^[13]。但是, SVM 同时存在一些不足,主要表现为: SVM 的计算过程需要相关既有经验参数的参与,主要包括了核参数以及惩罚因子,这两个在 SVM 中起到重要作用的参数的选择通常基于使用者的既有经验,这使得 SVM 模型的通用性大大降低。

模拟退火(Simulated annealing, SA)属于智能优化方法的一种,该方法具备多目标优化的能力,计算成本低、使用范围广,能够很好的满足本文的 SVM 参数优化的需求^[14]。

权衡以上所提各项方法的优缺点后可知: EMD 能够实现非线性、非平稳的信号多尺度分析,将信号分解; PE 作为一种复杂性测度,能够实现非线性信号的动力学突变检测,构造信号特征向量; SVM 算法能够实现非线性小样本数据分类,实现故障分类与诊断。以这三种方法为主要思想,即可实现对非线性信号的多尺度分解并基于小样本的数据分类。同时针对各方法的固有缺陷,逐条提出改进措施: 利用 EEMD 改善 EMD 的模式混叠,利用 MPE 解决 PE 的单一尺度问题,利用 SA 改进 SVM 的核参数和惩罚因子参数选择,从而,最大程度的提高该信号处理理论的鲁棒性和精确度,实现轴承故障的准确分类。

1 EEMD 方法

经验模态分解方法能够很好地处理非平稳、非线性信号,能够不依赖于先验基函数,而针对信号自有特性进行幅值多尺度分解,故具有很好的自适应性^[15]。但该方法易出现模式混叠^[16]。针对该缺点, Huang 和 Wu 提出了 EEMD 方法,在信号不同尺度中加入多次平均后的噪声,基于白噪声的统计随机性质,使信号成分自动映射到与背景白噪声相关的尺度平面经过多次平均后,噪声会近似成为 IMF^[17-18], EEMD 相对较为成熟,此处不再赘述其算法原理,仅以一显式信号对 EEMD 的模式混叠现象的抑制效果加以描述:

$$\text{令 } x(t) = x_1(t) + x_2(t) \quad (1)$$

$$x_1(t) = 10 \sin(2\pi 10t) \quad (2)$$

式中 $x_2(t)$ ——幅值为 2, 频率为 200Hz 的间断高频

正弦信号。

图 1 为 $x_1(t)$ 的波形图。分别利用 EMD 及 EEMD

对 $x(t)$ 进行分解, 结果见图 2、图 3。




图 1 $x_1(t)$ 的波形图




图 2 EMD 分解后的波形图




图 2 及图 3 反映了模态分解及经验模态模态分解

后的信号形态, 对上述得到的结果进行频带的分析, 可知在 IMF1 的信号分量中, 既存在了间断信号的成分, 同时也出现了一些频率较低的成分, 而 IMF2 中也覆盖了一些间断成分, 也就是说, 得到的结果中的模态分离并没有很好的实现, 不符合我们的理论分析结果, 无法有效的反映信号的实际特征。




图 3 EEMD 分解后的波形图

由图 4 可以看出, IMF1 中只含有间断信号, 低频分量被分解到了 IMF3 中。从以上分析结果可以看出, EEMD 分解较好地改善了 EMD 分解过程中存在的模态混叠现象。

2 多尺度排列熵

该算法的信号处理流程从待分析信号的粗粒化开始, 通过对信号各个局部尺度上的排列熵的分析, 进行多尺度考虑下的信号特性分析。针对具体信号的粗粒化过程, 本文举例如下:

$$y^s(j) = \frac{1}{s} \sum_{i=(j-1)s+1}^{js} x(i) \quad (3)$$

式中 s ——尺度因子;

$y^s(j)$ ——粗粒化数据排列。

由上述公式可知, 在尺度因子为 1 的情况下, 上述操作得到的处理结构即为原信号, 在这种情况下, 多尺度排列熵即退化为单一尺度条件下的排列熵。依据上述概念对信号进行处理, 即可得到多尺度条件下的信号排列熵特性^[19]。

排列熵的计算与算法参数联系密切, 不同的嵌入维数和延迟时间, 会对排列熵的计算结果产生较大影响。其中, 前者的取值范围为 3 到 7, 当嵌入位数过大时, 会使得相空间的计算繁琐, 增大算法所需要的计算时间, 当嵌入维数过小时, 会使得算法中的重构的信息太少, 从而无法实现突变信号的提取检测。由表 1 可以看出, 当 $m=7$ 时, 计算时间耗时较大延迟时间 t 对时间序列的计算影响较小, 由图 4 可知, 针对白噪声计算相对应的排列熵时, 延迟时间在其中的作用体现的并不强烈, 故综合考虑, 本文选取 $q=6$, $t=1$ 。

在多尺度排列熵计算过程中, 尺度因子 s 错误! 未找到引用源。决定了信号在该尺度下的排列熵表征特性, 当该尺度因子为 1 时, 多尺度排列熵

即退化为排列熵, 无法发挥多尺度排列熵的多尺度特性, 因此需要针对具体信号特征选择适当**错误! 未找到引用源。**值, 本文对信号进行多尺度排列熵分析, 计算各一致尺度下表征不同状态的信号的能量, 利用信号能量来表征喜好贡献特性, 选择 $s = \arg \max \left[\sum_{i=1}^4 S_{i,s}^2 \right]$ 作为尺度因子进行多尺度排列熵分析。

表 1 不同嵌入维数下排列熵的计算时间

嵌入维数 q	3	4	5	6	7
计算时间/s	0.055 46	0.080 73	0.323 18	1.877 93	12.868 8




图 4 高斯白噪声信号在不同延迟时间下的排列熵

3 SA-SVM 方法

针对 SVM 的多参数选择问题, 文中利用 SA 优化方法来实现, 对该 SA-SVM 算法进行流程解析如下:

- 1) 设置参数初值, 主要包含 Metropolis 初始值数目、核函数及参数上下限。
- 2) 基于核函数和参数上下限进行随机数生成, 构成 SVM 原始结构, 利用已知样本性数据记性模型结构的训练, 并用得到的训练后的模型进行检验样本的测试, 得到相应的分类结果, 分析准确率。
- 3) 在此核函数和参数的上下限生成一随机扰动, 进行核函数和参数更新, 然后利用给定样本针对更新后的 SVM 进行训练, 同样进行样本分类, 得到准确率结果。
- 4) 按 Metropolis 准则, 即接受或放弃新参数。
- 5) 重新进行步骤 3) 到步骤 5) 的操作内容, 实现一次 Metropolis 重复计算。
- 6) 判断最优适应值是否符合需求, 若符合,

则计算结束, 输出最优适应值对应的核函数、参数及其对应的 SVM 模型和分类结果; 若不满足, 则逐步减小退火温度, 即衰减, 重复步骤 3), 步骤 4), 步骤 5, 直至满足收敛条件^[20]。

4 实验研究

4.1 试验台与测试系统

为了验证多尺度本征模态排列熵和 SA-SVM 算法的有效性, 设计轴承故障试验台。试验台如图 5 所示, 由驱动电机、联轴器、齿轮箱和磁粉制动器等组成。利用此试验台可模拟正常轴承、外圈故障轴承、内圈故障轴承、滚动体故障轴承四种状态, 故障形式通过线切割, 在外圈、内圈和滚动体上开槽来实现, 各种状态轴承如图 6 所示。在实验台整个运行过程中, 采集振动加速度信号, 采样频率为 12 kHz, 采样点数为 4 096。




图 5 轴承故障模拟试验台

4.2 诊断结果

文中利用滚动轴承正常状态、外圈故障、内圈故障、滚动体故障进行故障信号的采集, 各 20 组, 共 80 组数据。



(a) 正常




(b) 外圈故障




(c) 内圈故障

(d) 滚动体故障


图6 轴承状态图




(a) 正常



(b) 外圈故障




(c) 内圈故障




(d) 滚动体故障


图7 时域波形



(a) 正常



(b) 外圈故障



(c) 内圈故障




图8 小波滤噪后的波形




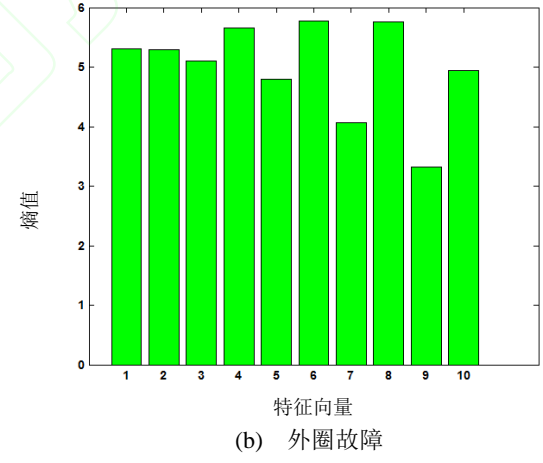

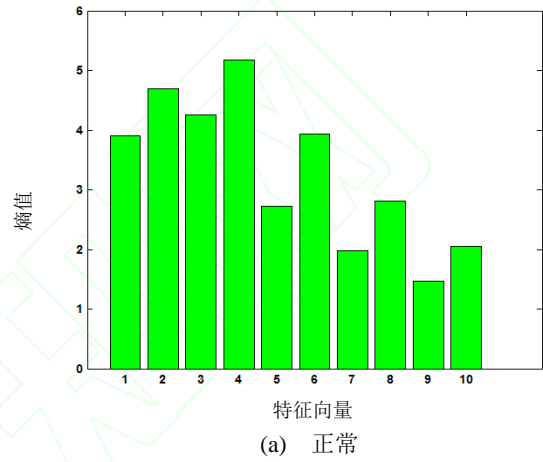




图9 EEMD 分解后的波形





(d) 滚动体故障

图 10 多尺度时频排列熵




图 11 不同尺度下的排列熵及其能量




图 13 SVM 分类结果




图 14 SA-SVM 分类结果

试验采集到的数据波形见图 7。从图 7 我们可以分析得到, 轴承外圈故障、内圈故障和滚动体故障振动信号中的冲击比正常情况下明显, 但背景噪声干扰较大, 只通过图 7 的时域波形无法实现状态分类与确定。基于信号降噪考虑, 对样本数据首先进行小波滤波处理, 文中采用的小波基函数为 DB4 小波, 利用小波域软阈值去噪算法对含噪信号进行分解、压缩、重构。图 8 为经过小波滤波后的时域波形, 为了进一步说明小波去噪的作用, 以外圈故障信号作为目标, 进行去噪前后幅值分布分析, 如图 12, 从图中可以看到, 经过小波去噪后, 信号中代表无意义噪声的低幅值成分出现频次减小, 同时, 能够表征振动特性的中高幅值成分出现频次相应的增加, 也就是说, 小波去噪能够滤除部分背景噪声, 提高故障轴承振动信号中冲击成分的比例。实际上, 根据小波降噪的多尺度分解重构原理分析, 可以较为轻易的得到上述结论, 本文仅为了直观起见, 以外圈故障信号为例, 利用图 12 进行了具体的去噪效果可视化说明。图 8 无法提供有效的正常与非正常轴承的分类效果, 其中正常轴承和滚动体故障轴承、外圈故障轴承和内圈故障轴承这两组信号之间的分类效果尤其低下。接着, 采用具有良好时频分析能力的 EEMD 方法对小波降噪后的数据进行分解, 得到若干个 IMF 分量, 分解后的前 5 个 IMF 示于图 9 中。因前 5 个 IMF 分量蕴含了轴承振动信号中的绝大部分信息, 故对每一组样本数据分解后前 5 阶固有模态分量进行 MPE 的计算, 将得到的多尺度条件下熵值作为表征信号特性的信号特征参数作为 SVM 分类器的特征向量, 针对整体样本数据进行多尺度排列熵参数矩阵构成, 即可得到 4 组不同类型信号的特征向量矩阵, 维度为 $4 \times 20 = 80$ 。利用 **错误! 未找到引用源。** 准则进行尺度因子 s 的计算, 计算各尺度 s 下的 $\sum_{i=1}^4 s_{i_s}^2$ **错误! 未找到引用源。**, 取小波降噪后的四种状态之间能量最大的 s 。结果见

图 11, 得到尺度因子 $s=3$ 。特征向量计算过程中, 参数嵌入维数 $q=6$, 延迟时间 $t=1$ 。图 10 为计算后的四组多尺度本征模态排列熵。再次, 将正常、外圈故障、内圈故障、滚动体故障四种状态下的轴承特征向量, 各取 5 组数据样本作为 SA-SVM 的训练样本, 训练 SA-SVM, (其中 1, 2, 3, 4 分别对应正常、外圈故障、内圈故障、滚动体故障轴承状态)。最后, 将所有数据分别输入训练好的 SVM 分类器和 SA-SVM 分类器中进行模式识别。识别输出结果如图 13 和图 14 所示。由图 13 可以看出, 有一个样本被错误分类, 即将内圈故障误判为外圈故障, 由图 14 可知, 经模拟退火算法优化后的 SVM 方法有很好的分类效果, 正确识别率为 100%。

综上所述, 本文提出的多尺度本征模态排列熵能准确提取轴承故障特征, SA-SVM 能较好地实现列车轴承故障分类。

5 结论

针对振动信号的非线性、非平稳性, 本文提出了多尺度本征模态排列熵和 SA-SVM 的故障诊断方法, 并基于实际城轨列车轴承的故障数据进行了算

法验证, 可得如下结论:

(1) EMD 能够很好地处理非线性、非平稳信号, 但存在模式混叠, EEMD 克服了模式混叠, 能很好地还原信号的本质。

(2) 通过多尺度本征模态排列熵能有效地提取出轴承故障特征信息, 从而构建轴承振动信号的特征集。

(3) 通过 SA 对 SVM 核心参数进行优化, 运用优化后的 SVM 方法实现了轴承故障的模式识别, 并进行了实际信号的算法测试, 证明了所提算法的有效性。

通过对实际列车轴承故障振动信号的分析, 表明基于多尺度本征模态排列熵和 SA-SVM 的故障诊断方法能有效地应用于轴承故障诊断。

参 考 文 献

- [1] HE Q, WANG J, Hu F, et al. Wayside acoustic diagnosis of defective train bearings based on signal resampling and information enhancement [J]. Journal of sound and vibration, 2013, 332(21):5635-5649
- [2] 唐贵基, 邓飞跃, 何玉灵. 基于自适应多尺度自互补 Top-Hat 变换的轴承故障增强检测 [J]. 机械工程学报, 2015, 51(19):93-100.
- TANG Guiji, DENG Feiyue, HE Yuling. Enhanced detection of bearing faults based on adaptive multi-scale self-complementary Top-Hat transformation [J]. Journal of mechanical engineering, 2015, 51(19):93-100.
- [3] 隋文涛, 张丹, Wilson Wang. 基于 EMD 和 MKD 的滚动轴承故障诊断方法 [J]. 振动与冲击, 2015, 34(9):55-59.
- SUI Wentao, ZHANG Dan, Wilson Wang. Fault diagnosis of rolling element bearings based on EMD and MKD [J]. Journal of vibration and shock, 2015, 51(19):93-100.
- [4] 苏文胜, 王奉涛, 张志新. EMD 降噪和谱峭度法在滚动轴承早期故障诊断中的应用 [J]. 振动与冲击, 2010, 29(3):18-21.
- SU Wensheng, WANG Fengtao, ZHANG Zhixin. Application of EMD denoising and spectral kurtosis in fault early diagnosis of element bearing [J]. Journal of vibration and shock, 2010, 29(3):18-21.
- [5] 张志刚, 石晓辉, 陈哲明. 基于改进 EMD 与滑动峰态算法的滚动轴承故障特征提取 [J]. 振动与冲击, 2012, 31(22):80-83.
- ZHANG Zhigang, SHI Xiaohui, CHEN Zheming. Fault feature extraction of rolling element bearing based on improved EMD and sliding kurtosis algorithm [J]. Journal of vibration and shock, 2012, 31(22):80-83.
- [6] 徐卓飞, 刘凯, 张海燕, 王丹. 基于经验模态分解和主元分析的滚动轴承故障诊断方法研究 [J]. 振动与冲击, 2014, 33(23): 133-139.
- XU Zhuofei, LIU Kai, ZHANG Haiyan, WANG Dan. A fault diagnosis method for rolling bearings based on empirical mode decomposition and principal component analysis [J]. Journal of vibration and shock, 2014, 33(23): 133-139.
- [7] WU Z H, HUANG N E. Ensemble empirical mode decomposition: A noise-assisted data analysis method [J]. Advanced in adaptive data analysis, 2009, 1(1):1-41.
- [8] BANDT C, POMPER B. Permutation entropy: a natural complexity measure for time series [J]. Physical review letters, 2002, 88(17):1-4.
- [9] YAN R Q, LIU Y B, GAO R X. Permutation entropy: A nonlinear statistical measure for status characterization of rotary machine [J]. Mechanical system and signal processing, 2012, 29:474-484.
- [10] 冯辅周, 饶国强, 司爱威. 基于排列熵和神经网络的滚动轴承异常检测与诊断 [J]. 噪声与振动控制, 2013, 33(3): 212-217.

FENG Fuzhou, RAO Guoqiang, SI Aiwei. Abnormality detection and diagnosis of rolling bearing based on permutation entropy and neural network [J]. Noise and vibration control, 2013, 33(3): 212-217.

[11] 冯辅周, 饶国强, 司爱威. 排列熵算法研究及其在振动信号突变检测中的应用 [J]. 振动工程学报, 2012, 25(2): 221-224.

FENG Fuzhou, RAO Guoqiang, SI Aiwei. Research and application of the arithmetic of PE in testing the sudden change of vibration signal [J]. Journal of vibration engineering, 2012, 25(2): 221-224.

[12] 郑近德, 程军圣, 杨宇. 多尺度排列熵及其在滚动轴承故障诊断中的应用 [J]. 中国机械工程, 2013, 24(19): 2641-2646.

ZHENG Jinde, CHENG Junsheng, YANG Yu. Multi-scale permutation entropy and its applications to rolling bearing fault diagnosis [J]. China mechanical engineering, 2013, 24(19): 2641-2646.

[13] 武兵, 林健, 熊晓燕. 基于支持向量回归的多参数设备故障预测方法 [J]. 振动、测试与诊断, 2012, 32(5): 791-795.

WU Bing, LIN Jian, XIONG Xiaoyan. Method of mechanical equipment fault prognosis based on multi-parameter support vector regression [J]. Journal of vibration, measurement & diagnosis, 2012, 32(5): 791-795.

[14] 胡玉霞, 张红涛. 基于模拟退火算法-支持向量机的储粮害虫识别分类 [J]. 农业机械学报, 2008, 39(9): 108-111.

HU Yuxia, ZHANG Hongtao. Recognition of the stored-grain pests based on simulated annealing algorithm and support vector machine [J]. transactions of the Chinese society for agricultural machinery, 2008, 39(9): 108-111.

[15] 张超, 陈建军. EEMD 方法和 EMD 方法抗模态混叠对比研究 [J]. 振动与冲击, 2010, 29(S): 87-90.

ZHANG Chao, CHEN Jianjun. Contrast of ensemble empirical mode decomposition and empirical mode decomposition in modal mixture [J]. Journal of vibration and shock, 2010, 29(S): 87-90.

[16] 李昌林, 孔凡让, 黄伟国. 基于 EEMD 和 Laplace 小波的滚动轴承故障诊断 [J]. 振动与冲击, 2014, 33(3): 63-69.

LI Changlin, KONG Fanrang, HUANG Weiguo. Rolling bearing fault diagnosis based on EEMD and laplace wavelet [J]. Journal of vibration and shock, 2014, 33(3): 63-69.

[17] WU Z H, HUANG N E. Ensemble empirical mode decomposition: A noise assisted data analysis method [J]. Advances in adaptive data analysis, 2009, 1:1-41.

[18] 雷亚国, 孔德同, 李乃鹏, 等. 自适应总体平均经验模态分解及其在行星齿轮箱故障检测中的应用 [J]. 机械工程

学报, 2014, 50(3): 64-70.

LEI Yaguo, KONG Detong, LI Naipeng, et al. Adaptive ensemble empirical mode decomposition and its application to fault detection of planetary gearboxes [J]. Journal of mechanical engineering, 2014, 50(3): 64-70.

[19] 任静波, 孙根正, 陈冰, 等. 基于多尺度排列熵的铣削颤振在线监测方法 [J]. 机械工程学报, 2015, 51(9): 206-212.

REN Jingbo, SUN Genzheng, CHEN Bing, et al. Multi-scale permutation entropy based on-line milling chatter detection method [J]. Journal of mechanical engineering, 2015, 51(9): 206-212.

[20] 纪华, 马伏龙. 模拟退火算法与支持向量机在机械故障诊断中的应用 [J]. 宁夏大学学报, 2014, 35(2): 141-143.

JI Hua, MA Fulong. The application on the simulated annealing algorithm and the support vector machines in mechanical fault diagnosis [J], 2014, 35(2): 141-143.

作者简介: 姚德臣(通信作者), 男, 1984 年出生, 博士, 副教授。主要研究方向为机械设备故障诊断、车辆动力学、转子动力学等

E-mail: yaodechen@bucea.edu.cn