

文章编号: 1001-0920(2011)01-0001-09

基于数据驱动的故障诊断方法综述

李 晗, 萧德云

(清华大学 自动化系, 北京 100084)

摘 要: 首先介绍了基于数据驱动的故障诊断方法研究动机和国内外发展现状, 以新的视角将现有故障诊断方法分为基于数据驱动的方法、基于分析模型的方法和基于定性经验的人工智能方法, 说明了该方法在整个体系中的地位, 并从数据利用及其与基于分析模型的方法比较等方面探讨了该方法的应用背景; 然后综述了按照新分类中基于数据驱动故障诊断的现有方法, 分析比较了各方法的区别和联系; 最后指出了基于数据驱动故障诊断方法的几个具有前景的研究方向.

关键词: 故障诊断; 数据驱动; 统计分析; 信号处理; 定量人工智能方法

中图分类号: TP273

文献标识码: A

Survey on data driven fault diagnosis methods

LI Han, XIAO De-yun

(Department of Automation, Tsinghua University, Beijing 100084, China. Correspondent: XIAO De-yun, E-mail: xiaody@tsinghua.edu.cn)

Abstract: Research motivation and current trends on data-driven fault diagnosis are firstly introduced. Then new classification of existing fault diagnosis approaches, which are data-driven methods, analytical model based methods and qualitative knowledge based methods, is proposed to show the status of data-driven methods in the framework. The basic application background is further discussed in terms of data requirements and comparison with analytical model based methods. The state-of-art methods as well as their connections and differences are analyzed in detail. Finally, several potential research directions are also summarized.

Key words: fault diagnosis; data driven; statistical analysis; signal processing; quantitative-based artificial intelligence methods

1 引 言

近 20 年来, 现代化工、冶金、机械、物流等工业呈现向大型化、复杂化方向发展的新趋势, 这些大型复杂工业过程的一个共同点就是一方面无法完全依靠传统方法建立精确的物理模型进行管理监控, 另一方面又时刻产生大量反映过程运行机理和运行状态的数据. 基于实际限制、成本优化、技术商机等因素的考量, 如何利用这些海量数据来满足日益提高的系统可靠性要求已成为亟待解决的问题, 其中基于数据驱动的故障诊断技术是一个重要的方面. 由于大型复杂系统需要监控的变量数大幅度增加, 获得的过程数据与小型简单过程相比呈数量级增长, 若仍采用 PID 闭环控制来补偿扰动和突变, 则需要补偿的数量过多, 导致控制器负担过重, 生成的小故障可能传播为灾难

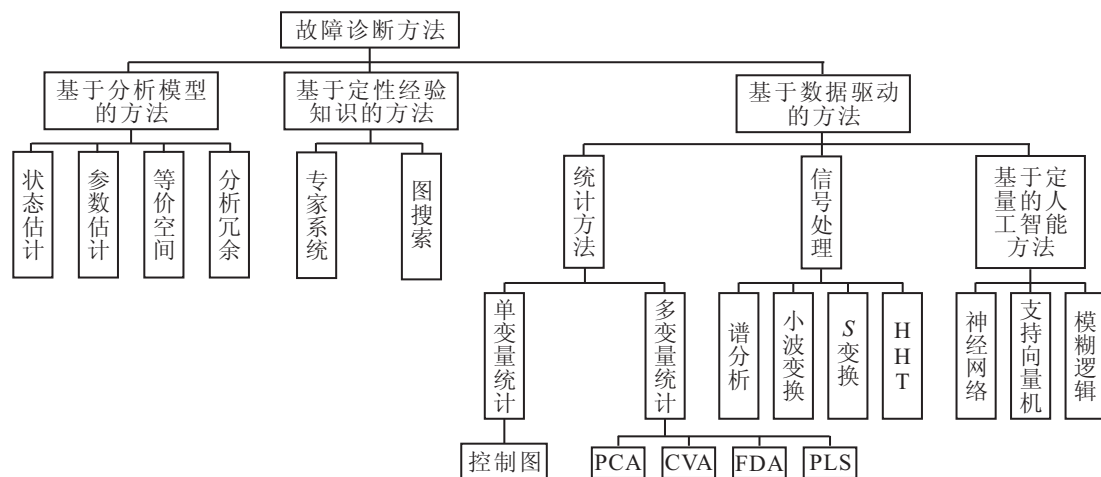
性的大故障. 如北京东方化工厂 1997 年 6 月发生乙烯装置起火爆炸事故, 直接经济损失达十亿元, 间接经济损失无法估量; 2005 年吉林市中石油吉林石化公司双苯厂连续发生爆炸, 形成特大环境污染事故; 胜利油田由于没有先进的输油检漏系统, 每年管道漏油造成的经济损失达上千万元^[1].

基于数据驱动的故障诊断是基于数据驱动控制和应用方法的一个重要方面, 已成为近年来热门的研究领域. 国际上, 美国 University of Minnesota 于 2002 年主办了题为“IMA hot topics workshop: Data-driven control and optimization”的研讨会. IEEE 从 2008 年开始举办 The IEEE Int Workshop on Defect and Data Driven Testing, 专注于各类基于数据的异常检测和故障诊断技术. 在国内, 国家自然科学基金委于 2008 年

收稿日期: 2010-03-02; 修回日期: 2010-06-22.

基金项目: 国家自然科学基金项目(60736026, 60904044).

作者简介: 李晗(1986—), 男, 博士生, 从事管道系统故障诊断的研究; 萧德云(1945—), 男, 教授, 博士生导师, 从事辨识建模、动态系统故障诊断等研究.



召开了“基于数据的控制、决策、调度和故障诊断”研讨会;2009年第6届全国技术过程故障诊断与安全学术性学术会议三场大会报告中有两场是关于基于数据驱动领域内的。纵观该领域的发展历史,基于数据驱动的故障检测、诊断、辨识技术正处于学术界和工业界全面重视的阶段,其系统理论和方法有待进一步深入研究。

大型过程工业控制中的故障通常被定义为至少一个系统特征或者变量出现了不被允许的偏差^[2]。Kesavan等人^[3]指出了其中几种典型的故障:过程参数变化、扰动参数变化、执行器/传感器故障、执行器饱和。而数据监控技术通过过程信息辨别和异常报警为大型工业流程正常工作提供了技术支持。Raich等人^[4]提出了数据监控的4个步骤:故障检测、故障辨识、故障诊断和过程恢复。故障检测判断是否发生故障;故障辨识从过程的众多变量中确定受故障影响最大的变量;故障诊断确定故障发生的原因;过程恢复对故障进行干预,去除故障对系统的影响。以上4个步骤并不是缺一不可,有时可以将前2步合并处理,而前3个步骤是故障诊断研究的重点关注领域,最后1步一般需要单独处理。

本文将故障诊断领域的方法划分为3类:基于分析模型的方法、基于定性经验知识的方法和基于数据驱动的方法,如图1所示。基于分析模型的方法适用于能建模、有足够传感器的“信息充足”的系统,需要过程较精确的定量数学模型,而要建立过程的数学模型则必须了解过程的机理结构。参数估计法^[6]、状态估计法^[7]、分析冗余法^[8]等都是典型的基于分析的方法,其理想状态是能够获得精确的模型。但在实际过程中存在“未建模动态”,这种模型不精确性虽然使得模型的鲁棒性较好,但同时也容忍了故障的发生,增加了确定故障发生类型的难度。基于经验知识的方法适用于不能或不易建立机理模型、传感器数不充分

的“信息缺乏”的系统^[5],包括符号有向图^[9]、专家系统^[10]等。基于分析模型的方法和基于定性经验知识的方法更适用于具有较少输入、输出或状态变量的系统,对于具有海量数据的系统则使用成本过高^[11-13]。

在当今的大型系统中,一方面,基于分析模型的方法不可能获得复杂机理模型的每个细节;另一方面,基于定性经验知识的监控方法需要很多复杂高深的专业知识以及长期积累的经验,这超出一般工程师所掌握的范围,从而变得不易操作。目前,多数企业每天都产生和存储较多运行、设备和过程的数据,这些数据分为正常条件下和在特定故障条件下收集的数据,包含着过程中各方面的信息。如何利用这些数据,实现基于数据驱动的生产过程和设备的故障诊断、优化配置和评价是一个值得研究的问题。本文着重从基于数据故障诊断的思想、应用背景、方法、发展、对比等方面全面回顾基于数据驱动的故障诊断方法。

2 基于数据驱动故障诊断方法的应用背景

首先,基于数据驱动的故障诊断方法可以看作是基于数据驱动的控制优化方法的一个子领域,后者的核心思想是如何利用受控系统的在线和离线数据^[14];其次,在目前的实际研究中,前者往往成为相对独立的体系。周东华等人^[15]提出的基于数据驱动的故障诊断是对过程分析数据进行分析处理、在不需知道系统精确解析模型的情况下完成故障诊断。

基于数据驱动的故障诊断方法采用的数据源于当前采样在线数据和系统存储的大量历史离线数据。所以,明确离、在线数据的区别和对于数据的要求是实现数据利用的第1步。在线数据是当前受控系统的I/O数据,捕捉了系统的最新变化,反映了一个过程或事件的时变特性;离线数据相对于在线数据而言,主要指存储的大量控制器的历史I/O数据、传感器记录数据、过程采样数据等。与在线数据相比,离线数据

数量多、信息量丰富,不会产生在线数据只包含一次采样过程的一部分、信息丢失以及测量偏差等现象。目前,基于离线数据的方法远多于基于在线数据的方法,应用也更加广泛。一般来说,基于数据驱动的故障诊断方法对离线数据的要求有:1)信息充足。好的离线数据在采样空间中均匀分布,该条件类似于系统辨识中数据的持续激励条件^[16]。2)完整性。完整性指离线历史数据能包含受诊断对象各个方面的情况,包括正常情况和各种故障时的情况。虽然一次采样数据仅反映系统的某一个状态,不能包含状态空间中的所有状态,但数据的完整性是体现在统计意义上的概念。为了满足离线数据的完整性,需要在采集到数据后进行后验分析,例如模式分类。这样若数据在完整性上还有缺陷,则可以有针对性地进行弥补。近年来,工业过程大型化、复杂化,监控技术越来越向时间多尺度方向发展。例如先进过程控制中,ms级的阀门控制是实时的,而在管理层有关最终产品的组合决策却以季度为单位进行,这样就要求基于离线的数据监控方法与在线任务相结合。同时,计算机数据处理能力的高速发展也为基于离线数据的监控方法处理实时数据提供了坚实的技术支撑。

虽然随着工业流程日益大型化、复杂化,要实现整个系统的建模非常困难,但故障诊断采用传统基于建立近似模型的方法仍然十分普遍。实际情况中,可能只有各个小规模子系统的输入输出关系可以建立子系统较精确的物理模型,但若仅将子系统的模型组合起来形成整体系统,则会忽视子系统间的联系,如变量间的关联性、系统的非线性等。在这种情况下,基于数据驱动的故障诊断方法可以作为基于机理模型方法的重要补充。目前采用的分布式控制系统(DCS)可以提供一个用于全局管理监控的平台,以此来提高产品质量、减低生产能耗、降低污染排放等,其优点是有大量高质的过程数据可以用于过程优化和监控^[17]。输油管线监控和数据采集(SCADA)系统是一类典型的集故障诊断、调度、优化配置于一体的分布式管理监控系统,它集成了各种机理模型,能够极大挖掘收集到的各种数据完成管理、调度、监控、报警,如图2所示。系统由1个监测调度中心、各

泵站控制终端和通信网络构成。监测调度中心定时接受各泵站终端采集的数据,将全线的数据集集中起来,根据不同的决策目标进行不同数据的组合分析,实现泵站的各种操作和调度,如泄漏故障的侦测等。另外,监测调度中心根据数据分析的结果发出指令给一个或多个泵站终端,改变管线系统运行状态。整个系统的控制、调度、决策、故障诊断都是基于大量在线数据分析完成的。

3 基于数据驱动的故障诊断方法概述

基于数据驱动的故障诊断方法主要有基于统计分析的方法、基于信号分析的方法以及基于定量知识的数据分析方法,下面分别予以介绍。

3.1 基于统计分析的故障诊断方法

基于统计分析的方法主要依靠分析过程数据统计量,从其中的变化提取特征。应用统计理论进行故障诊断的前提是系统中必须出现故障,否则过程数据的特征统计量只能在一定的、可以接受的范围内波动。虽然某个变量每次观测的具体数值不能准确预测,但其平均值和方差值等特征统计量会保持不变,这种特性称为特征统计量的可重复性。利用该可重复性可以针对特定的变量设定特定的门限值,从而有效地检测出异常状态。基于统计分析的方法可以分为单变量统计方法和多变量统计方法,其中后者是故障诊断主要的应用方法。

3.1.1 基于控制图法的故障诊断

门限值法在单变量统计方法中较为重要,其基本思想是:通过定义一个过程变量的门限值,规定其值的允许变化范围,超出该范围即认为发生了故障。休哈特控制图^[18-19]是门限值法著名的应用之一,也是当前产品质量监控的重要工具。如图3所示,该图是一种画在平面直角坐标系中标有控制限的图像,横坐标表示检测时间,纵坐标表示测得的目标特征值,中心线表示目标值CL,实线表示控制上限UCL和下限LCL。标准的控制图模型为

$$UCL = \mu_{\omega} + L\sigma_{\omega}, \quad (1)$$

$$CL = \mu_{\omega}, \quad (2)$$

$$LCL = \mu_{\omega} - L\sigma_{\omega}. \quad (3)$$

其中: ω 是统计变量, μ_{ω} 是均值, σ_{ω} 是标准偏差, L 是常数。控制图按其用途可分为两类:一是变量控制图,用于分析生产过程中有关质量特性值的变化情况,检测工序是否处于稳定受控状态;二是特性控制图,用于发现批次产品是否符合要求,以预防不合格品出厂。前者一般用于监控可量化表示的监测量,后者对应监测非量化特性。

常用的变量控制图是 \bar{x} 控制图和 R 控制图,其

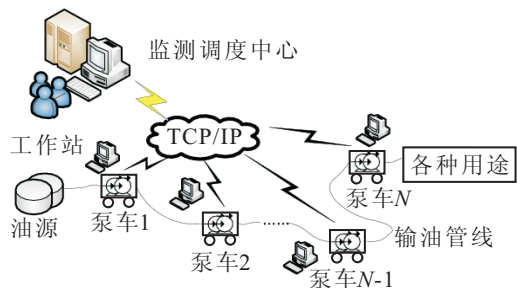


图2 输油管线SCADA系统的常用实现结构




图3 休哈特控制图

CL 取值分别为采样值平均值和多次采样极值差的平均值, UCL 和 LCL 分别按一定规则选取. 当总采样次数较大或为变量时, S 控制图比 R 控制图更常用, 其中 S 为采样值的标准偏差^[20]. 变量控制图可以提供系统异常的信息, 用来区分引起质量波动的原因是偶然的还是系统的, 从而判断生产过程是否始终处于受控状态. 当在横轴上描绘出取得某过程变量不同时刻的采样值时, 正常状态下其值将在中心线上下波动, 形成某种典型分布; 如果除去偶然偏离出控制界的采样外, 描绘出的分布还是偏离了典型分布, 则可判断为异常情况发生. 特性控制图则经常用于判断产品质量“有缺陷”或“无缺陷”、“相容”或“不相容”、“合格”或“不合格”. 这类图的 CL, UCL, LCL 均用概率值表示. 例如, 检验一批次产品的不合格率是否超过门限, 从而判断这批产品是否合格以确定设备是否故障, 常见的有 P 控制图, C 控制图和 u 控制图^[20]. 为了更好地检测出过程中小的漂移, Page^[21]提出了累积和控制图, 它通过计算变量与其标称值的差值和来判断是否发生参数漂移故障. Robert 提出的指数加权滑动平均控制图对变量当前观测的数据和历史数据赋予不同的权重后计算加权和, 当加权和超过一定门限值时, 认为发生故障.

利用以上控制图设定监测门限值时没有考虑变量间的相关性, 仅从自身的历史数据出发得到统计特征量. 下面将要介绍的多变量统计分析方法将考虑包含在其他相关联变量中的信息进行故障诊断. 根据多变量历史数据, 利用多元投影方法将多变量样本空间降维形成反映数据主要变化的低维空间, 再将新观测数据投影到此低维空间, 利用特征统计量判断数据是否异常. 该类方法主要有主元分析法 (PCA), Fisher 判别分析法 (FDA), 偏最小二乘法 (PLS), 规则变量分析法 (CVA) 等.

3.1.2 基于 PCA 的故障诊断

PCA 技术^[22]将系统高维历史数据组成矩阵, 进行一系列矩阵运算后确定若干正交向量 (称为装载向量), 历史数据在这些向量上的投影反映数据变化最大的几个方向, 舍去数据变化较小的方向, 由此可将高维数据降维表示, 该方法即为 PCA 降维方法. 利用

PCA 技术降维后, 通常只需 2~3 维即可反映历史数据的大部分变化方向, 进而从海量数据中抓住主要部分, 极大简化数据利用.

假设历史数据矩阵为

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix}. \quad (4)$$

其中: n 表示观测次数, m 表示每次观测的变量数. 利用 PCA 技术进行故障诊断的原理是: 装载向量的个数确定了高维历史数据降维后的维度. 将新观测的数据向量 \mathbf{x} 投影到装载向量所指示的方向上, 利用 T^2 ^[23]和残差空间中的 Q 统计量^[24]可判定 \mathbf{x} 是否为异常数据, 从而判定是否故障.

运用 PCA 技术进行故障定位经典的方法是贡献图法^[25]. 当判断发生故障时, 定义故障贡献度函数, 分别计算 m 个变量的贡献度函数值, 并选取使函数值最大的变量作为引起故障的变量. Alcalá 等人^[26]证明了引起故障的变量其经典贡献度函数值不一定最大, 并指出在基于重构的贡献值计算方法下可以保证以上原则, 从而改进了故障定位方法. PCA 技术用于故障分类的原理是以包含各类故障信息的数据为训练数据, 推导出指示数据变化最大的几个方向的向量. 将新观测的数据 \mathbf{x} 代入预先定义的故障分类判别式中, 通常采用模式分类方法中的后验概率判别式^[27], 依据达到最大的故障概率来对故障进行归类. 文献 [28] 提出了以每类故障数据为训练数据分别建立 PCA 模型, 依次对新观测数据进行检验以确定属于哪种故障数据类或新的故障类.

对于采样间隔较短的化工过程, 除了考虑不同变量之间的互相关性, 还需要考虑自相关性, 即同一变量在不同采样时刻值的相关性. 简单的方法是将不同时刻的变量值对于采样次数取平均, 或利用动态 PCA 技术^[4], 将训练数据矩阵 \mathbf{X} 变为 $\mathbf{X}(h)$, 即

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_t^T & \mathbf{x}_{t-1}^T & \cdots & \mathbf{x}_{t-h}^T \\ \mathbf{x}_{t-1}^T & \mathbf{x}_{t-2}^T & \cdots & \mathbf{x}_{t-h-1}^T \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{x}_{t+h-n}^T & \mathbf{x}_{t+h-n-1}^T & \cdots & \mathbf{x}_{t-n}^T \end{bmatrix}, \quad (5)$$

其中 \mathbf{x}_t^T 是采样时刻 t 的 m 维观测数据向量. 此外, 与传统 PCA 方法训练数据 \mathbf{X} 只有变量和采样次数两维不同, 多向 PCA^[29]还加入了历史数据的不同批次, 是传统 PCA 方法的三维延伸.

从以上论述可以看出, PCA 本质上是对历史数据集所构成的输入空间作线性变换, 使得其只对服从高斯分布数据特征的提取效果明显. 但在多数情况

下,数据集具有其他任意分布,特别是在数据具有非线性结构、不能用线性分类的情况下,传统PCA方法显得力不从心,核PCA(KPCA)^[30]考虑了此问题.它是一种非线性PCA技术,首先通过一个非线性映射函数 ϕ 将历史数据映射到特征空间 F 的数据空间中;然后对 F 中的数据集运用PCA技术进行数据分类.而核技术应用于PCA的关键在于,通过预选的核函数代替映射函数 ϕ 作用时,要进行内积运算,不用必须找到 ϕ ^[31].Kramer^[32]还将PCA方法扩展为基于神经网络的非线性PCA,在某些数据具有非线性的情况下,非线性PCA神经网络比传统PCA能够更多地捕捉到数据变化.

3.1.3 基于Fisher判别分析的故障诊断方法

FDA^[33]是一种与PCA原理相同的线性降维方法,寻找较少的正交向量,将式(4)所示的高维训练数据 \mathbf{X} 只投射到这几个向量所指示的方向上,从而表征了数据中蕴含的系统运行特征.与PCA方法相比,FDA方法考虑了 \mathbf{X} 不同数据分类之间的关联信息,因此能提供比 \mathbf{X} 更优的低维表示,更加适合于故障分类.FDA方法极大化数据类之间的距离,极小化数据类内的距离,定义了描述以上概念的数据类间分散度矩阵 \mathbf{S}_w ,数据类内分散度矩阵 \mathbf{S}_b 和度量所有数据间方差程度的总分散度矩阵 \mathbf{S}_t . \mathbf{S}_w , \mathbf{S}_b , \mathbf{S}_t 之间的关系为

$$\mathbf{S}_t = \mathbf{S}_b + \mathbf{S}_w. \quad (6)$$

利用 \mathbf{S}_w , \mathbf{S}_b 和 \mathbf{S}_t 可确定FDA装载向量,由此利用FDA装载向量矩阵 \mathbf{W}_a 可以将一个 m 维的观测向量 \mathbf{x}_i 投射到更低维的 a 维空间($a < m$),即

$$\mathbf{z}_i = \mathbf{W}_a^T \mathbf{x}_i. \quad (7)$$

将FDA方法应用于故障分类的原理与PCA方法相同,将新的观测数据代入第3.1.2节中应用的故障分类判别式中,即可确定是哪类故障发生.

3.1.4 基于PLS的故障诊断方法

PCA方法找出训练数据 \mathbf{X} 变化最大的几个方向,代表这几个方向的向量组成装载矩阵对新观测数据进行归类,从而起到故障分类的作用.但缺陷是装载向量只反映了 \mathbf{X} 变化最大的几个方向,当这些方向不足以包含区分故障所需要的足够信息时,PCA方法将不能起到故障分类的作用.而PLS方法中设置了一个矩阵 \mathbf{Y} , \mathbf{Y} 的元素包含了故障信息,与PCA方法直接寻找 \mathbf{X} 变化最大的方向不同,PLS方法的思想是通过最大化 \mathbf{X} 和 \mathbf{Y} 之间的协方差来确定装载向量,这样找出的装载向量能够更准确地表现不同故障的差异,利于进行故障分类.

在PLS方法中,训练数据矩阵 $\mathbf{X} \in \mathbf{R}^{n \times m}$,形式(4),但行列将重新排列.假设有 p 类故障,每类故障观测到的向量数量分别为 $n_i (1 \leq i \leq p)$,且 $\sum_{i=1}^m n_i = n$. \mathbf{X} 中的前 n_1 行放置属于故障类1的观测数据, n_2 行放置属于故障类2的观测数据,以此类推.对应 \mathbf{X} 选取的 \mathbf{Y} 的一种形式如下:

$$\mathbf{Y} = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix}, \mathbf{Y} \in \mathbf{R}^{n \times p}. \quad (8)$$

在模式分类中,通常用“1”表示同类,“0”表示非同类.前 n_1 行只有第1列元素为1,其余元素为0,表示有 n_1 个数据属于故障类1,后 n_2 行与前 n_1 行数据线性无关,表示有 n_2 个数据属于故障类2,以此类推.

非迭代最小二乘算法^[34]和计算速度较快的SIMPLS算法^[35]是实现PLS方法的两种典型算法.求得PLS的装载向量后,可以应用与PCA方法相同的故障检测、辨识、分类的方法,如 T^2 统计量、 Q 统计量、贡献图法和判别式分析.

3.1.5 基于规则变量分析的故障诊断方法

DPCA和DFDA方法均考虑了变量之间的互相关和自相关性,但应用该类方法对一些具有强自相关性的系统进行故障诊断时,仍较为困难^[36].CVA子空间方法是一种基于过程数据的系统辨识方法,它最大化历史数据集和未来数据集之间的相关性,同时考虑了数据间的相关性和数据序列相关性.与PCA和DPCA方法相比,CVA方法能够降低故障的漏检率^[37].

CVA进行故障诊断的思路是利用过程数据辨识出系统的模型,然后根据该模型预测可观测量,通过对比实测量和观测量的差值判断过程是否出现异常.ARMA过程的状态空间模型为

$$\begin{cases} \mathbf{x}(k+1) = \mathbf{A}\mathbf{x}(k) + \mathbf{B}\mathbf{e}(k), \\ \mathbf{y}(k) = \mathbf{C}\mathbf{x}(k) + \mathbf{e}(k). \end{cases} \quad (9)$$

其中: $\mathbf{x}(k) \in \mathbf{R}^n$, $\mathbf{y}(k) \in \mathbf{R}^m$.首先定义过去信息向量为

$$\mathbf{y}_p = \begin{bmatrix} \mathbf{y}(k-1) \\ \mathbf{y}(k-2) \\ \vdots \\ \mathbf{y}(k-p) \end{bmatrix}, \quad (10)$$

未来信息向量为

$$\mathbf{y}_f = \begin{bmatrix} \mathbf{y}(k) \\ \mathbf{y}(k+1) \\ \vdots \\ \mathbf{y}(k+f-1) \end{bmatrix}, \quad (11)$$

形成历史数据集为

$$\mathbf{Y}_p = [\mathbf{y}_p(k) \ \mathbf{y}_p(k+1) \ \cdots \ \mathbf{y}_p(k+N-1)], \quad (12)$$

未来数据集为

$$\mathbf{Y}_f = [\mathbf{y}_f(k) \ \mathbf{y}_f(k+1) \ \cdots \ \mathbf{y}_f(k+N-1)]. \quad (13)$$

其中: k 是任意选取的当前时刻, p 是历史数据观测长度, f 是未来数据观测长度, N 是数据长度, \mathbf{Y}_p 和 \mathbf{Y}_f 的协方差矩阵分别是 Σ_{pp} 和 Σ_{ff} , 互协方差矩阵是 Σ_{fp} . CVA 的实现是对下式进行奇异值分解:

$$\Sigma_{ff}^{-1/2} \Sigma_{fp} \Sigma_{pp}^{-1/2} = \mathbf{U} \Sigma \mathbf{V}^T. \quad (14)$$

其中: \mathbf{U} ($\mathbf{U} \in \mathbf{R}^{mf \times mf}$) 的左 n 列记为 \mathbf{U}_n ; 奇异值矩阵 Σ ($\Sigma \in \mathbf{R}^{mf \times mp}$) 的前 $n \times n$ 对角矩阵为 Σ_n , 对角线元素按照值的大小减序排列, 前 n 个较大的对角线元素远远大于其余对角线元素; \mathbf{V} ($\mathbf{V} \in \mathbf{R}^{mp \times np}$) 的右 n 列记为 \mathbf{V}_n . k 时刻的状态 $\mathbf{x}(k)$ 通过下式估计:

$$\mathbf{x}_k = \Sigma_n^{1/2} \mathbf{V}_n^T \mathbf{U} \Sigma_{pp}^{-1/2} \mathbf{y}_p(k), \quad (15)$$

其中 $\mathbf{y}_p(k)$ 已知. 利用多重线性回归, 可以得到式 (9) 中 \mathbf{A} 和 \mathbf{C} 的估计 $\hat{\mathbf{A}}$ 和 $\hat{\mathbf{C}}$, 由此建立该 ARMA 过程的状态空间模型. 再根据预测值 $\hat{\mathbf{y}}$ 和实测值 \mathbf{y} , 利用 Q 统计量和贡献图法可以进行故障检测和诊断.

3.2 基于信号分析的方法

过程中某变量不同时刻采样值组成的信号中蕴含过程运行特征的各种信息. 基于信号分析的故障诊断方法就是利用各种信号分析技术提取信号时域和频域的特征, 例如利用幅值变化、相位漂移等方法确定过程的状态. Drif 等人^[38]对定子电流频谱的分析实现了三向异步电机的故障检测, 此后又指出分析功率谱能比分析电流频谱获取更多信息, 并利用异步电动机定子功率谱分析法实现了鼠笼型电机的故障检测. Nandi 等人^[39]总结了在电机故障检测中频域分析方法是常用的方法之一.

小波变换^[40]是一种可用于非平稳、时变信号的时频局部分析技术, 由短时傅立叶变换发展而来, 通过伸缩和平移等运算功能对信号进行多尺度的细化分析. 小波变换克服了短时傅立叶变换无法同时兼顾良好频率和时间分辨率的缺陷, 在时域和频域均可以

表征信号局部特征. 其时间窗和频率窗大小都可以改变: 在低频部分具有较高的频率分辨率和较低的时间分辨率, 在高频部分则具有较高的时间分辨率和较低的频率分辨率. 小波分析的这种能力使其能够分辨出信号某时刻的瞬态特征, 而且能保留信号的主要频域成分, 从而达到滤除噪声的效果. 文献 [41] 利用小波变换对信号进行多尺度分析, 提取信号在不同尺度上的特征用于故障诊断. [42] 将小波变换技术用于管道系统泄漏检测中, 选择特殊的小波基, 将压力信号的下降沿变换为极值小波系数, 从而检测并定位出泄漏. [43-45] 将小波变换与人工神经网络、支持向量机、模糊逻辑等其他方法相结合, 进行故障检测和分类.

S 变换^[46]是一种加窗傅里叶变换, 它将一维时域信号变换到二维时频域信号, 适合分析非平稳信号. 王成栋等人^[47]应用 S 变换诊断柴油机气阀机构故障, 将柴油机缸盖表面振动信号 S 变换后得到时频相平面图, 再利用图像分类法进行分类, 从而实现故障诊断. Livanos 等人^[48]将 S 变换应用于生理检测, 首次将心音图作 S 变换, 并且得出正确诊断结果. 实验还表明, 心音图的 S 变换比其短时傅里叶变换和连续小波变换更利于诊断出病症.

希尔伯特-黄变换 (HHT)^[49]是基于经验分解的信号处理方法. 信号 HHT 没有像傅立叶变换和小波变换那样选取固定的基函数将信号展开, 而是自适应将信号分解为若干“本征模式函数”(IMF), IMF 完全源自于信号本身. HHT 的自适应性使其适合非线性和非平稳过程分析. 文献 [50] 提出了改进的 HHT, 对比其与小波变换在滚动轴承故障诊断中的效果可以看出, 前者具有一定的优越性. 目前 HHT 的理论基础还在不断完善中, 可以预见其信号分析的优势将应用于故障诊断领域中.

3.3 基于定量知识的方法

基于知识的故障诊断方法不需要定量数学模型, 利用人工智能技术, 即通过教计算机如何学习、推理和决策等实现故障诊断^[13]. 运用的知识包含系统结构知识、经验规则知识、工作状态知识、环境知识等. 传统的故障诊断分类法中, 基于知识的故障诊断方法是单独一类, 分为定性方法和定量方法^[11-13]. 定性方法包括利用已知结果进行推理的图搜索方法和基于经验推断的专家系统方法, 其共同点是诊断不一定完全基于量化的数据, 更多是基于状态、特征、属性等非量化特征的变化. 定量方法所需知识源自大量的过程数据, 本文认为它是一种基于数据的故障诊断方法, 典型代表有基于人工神经网络的方法、基于支持向量机的方法和基于模糊逻辑的方法.

利用人工神经网络进行故障诊断, 其原理是先利

用训练数据(通常是大量的已知属性的样本)建立起故障识别和分类的映射;然后将训练好的网络用于新观测的数据进行异常情况的判断. 文献[51]收集了直流电机在不同故障下的参数和状态,然后组成训练数据,在数据和故障类别之间建立起映射,从而检测了电机的早期故障. [52]考虑了被检测系统的非线性和故障诊断方法对模型不确定性的鲁棒性. 定量的基于神经网络的方法还可以同定性的基于专家系统的方法相结合进行故障诊断. 专家系统故障诊断技术利用各领域长期实践中积累起来的经验建立知识库,并设计了一套模拟程序仿真人类的决策过程. 这种技术也不需要过程的模型,当决策规则建立后,在过程中收集各种数据作为决策依据. [53]将人工神经网络同专家系统相结合进行动态系统的故障诊断. 神经网络通常需要大量的样本数据用于训练,支持向量机(SVM)[54]克服了当数据不够时的困难. 它是一种适用于小样本情形下的模式分类技术,其基本思想是,当数据在本身维不可分时,利用核函数将数据投射到高维空间,根据不同原则[55]选取参数构造超平面进行数据分类,从而达到故障识别的目的. [56]以经典的 *tennessee eastman process* 生成数据表明,基于 SVM 的非线性故障分类技术比基于 FDA 的线性分类更优. [57]对比了神经网络和 SVM 应用于故障诊断的效果. [58]将多元统计分析方法与 SVM 相结合,先利用 PCA 方法提取数据的统计特征;然后利用 SVM 对特征进行分类. 模糊逻辑由 Zadeh 首次提出, [59]详细阐述了模糊逻辑应用于故障诊断的原理. 模糊逻辑故障诊断系统将采集到的各种数据量模糊化;然后根据模糊规则库推断由这些输入引起某种故障发生的可能性. 其中模糊化方法一般根据预先选取的隶属度函数将输入量转化为相应的隶属度;模糊规则库是该系统的关键和瓶颈,根据专家知识和经验建立;推断机制采用“IF... THEN...”型. 模糊逻辑系统类似于人工神经网络,也是一种重要的非线性映射模型,其独特之处在于能够更加充分有效地利用多种不同类别的数据.

4 结 论

本文对基于数据驱动的故障诊断方法进行了回顾. 首先,通过重新将现有故障诊断方法进行分类,介绍了该方法在故障诊断领域中的地位以及与其他类方法的关系;然后,着重研究了基于数据驱动故障诊断方法的应用背景,分析了故障诊断数据的要求及在实际应用中与基于分析模型方法的区别联系;最后,较全面地综述了现有基于数据驱动的故障诊断方法和各类方法的区别联系.

基于数据驱动的故障诊断方法还在不断完善和

向前发展中,以下是一些可能的发展方向:

1) 目前的数据驱动故障诊断技术主要基于大量的离线历史存储数据,而过程中采用的先进仪器设备和设计完备的软件系统使得数据的采集和获取日益简便. Choudhury 等人[60]介绍了当前化工过程领域内几种经典的数据压缩技术,及其对基于数据驱动分析技术在信息提取方面的影响,指出压缩因子大于3的压缩技术是无效的. 如何更加有效地压缩和保存海量数据及发展相关的数据预处理技术,将直接影响后期各类数据处理方法的选取,这是未来的一个研究领域.

2) 离线历史数据含有大量系统的运行机理知识和运行规律,而在线数据反映了最新的数据变化,蕴含了系统当前的状态变化. 目前的方法大多基于历史数据进行分析,必须将数据积累到一定量才能进行分析,这将阻碍诊断方法的实时更新,如何发展在线数据的分析理论将是今后发展的一个重要趋势. 例如, PCA, PLS 等方法在过程监控领域已经广泛应用,但该类方法的前提条件是需要历史数据作为训练数据,有时还需要针对各种故障分类数据,这对于目前的多层次、多尺度、多范围的复杂系统而言是不容易满足的. 而基于信号处理的数据驱动故障诊断方法,由于其可以实时采集特征变量的值变化,并通过信号处理的手段提取系统运行状态的特征,变得十分有前景. 当前这类方法主要基于小波分析技术,而 HHT 方法在处理非线性和非平稳过程信号的优势已经显现,完善其理论研究等一系列可应用于故障诊断的方法是有意义的工作.

3) 将基于数据驱动的方法与基于分析模型的方法进一步融合,在基于知识的故障诊断方法领域显得更加突出. 基于知识的方法涵盖系统的各种机理知识、数据知识和经验知识,基于数据驱动和基于模型的方法各有优缺点,如何使得两者相互支持、互相补充将成为一个有意义的研究方向.

4) 针对不同的大型复杂系统和其运行特点开发基于数据驱动的监控系统也是实际应用中亟待解决的问题. 该领域的研究更趋向工程化,将已有基于数据驱动的故障诊断方法应用于实际也是重要的研究方向. 例如,在野战长输石油管线系统开发输油故障检测的 SCADA 系统是一个有待提高和技术推广的应用领域.

参考文献(References)

- [1] 舒军星. 输油管道泄漏监测技术及在胜利油田中的应用[J]. 管道技术与设备, 2003, 20(2): 39-41.
(Shu J X. Leak monitoring technique for oil transport pipeline and its application in Shengli oil field[J]. Pipeline

- Technology and Equipment, 2003, 20(2): 39-41.)
- [2] Isermann R, Ballé P. Trends in the application of model based fault detection and diagnosis of technical processes[J]. Control Engineering Practice, 1997, 5(5): 709-719.
- [3] Parthasarathy K, Jay H L. Diagnostic tools for multivariable model-based control system[J]. Industrial and Engineering Chemistry Research, 1997, 36(7): 2725-2738.
- [4] Anne Raich, Ali Cinar. Statistical process monitoring and disturbance diagnosis in multivariable continuous processes[J]. AIChE J, 1996, 42(4): 995-1009.
- [5] Jie Chen, Ron J. Patton. Robust model-based fault diagnosis for dynamic systems[M]. Boston: Kluwer Academic Publishers, 1999.
- [6] Bagheri F, Khaloozadeh H, Abbaszadeh K. Stator fault detection in induction machines by parameter estimation using adaptive Kalman filter[C]. Proc of 2007 Mediterranean Conf on Control and Automation. Piscataway: IEEE, 2007: 1-6.
- [7] Li L L, Zhou D H. Fast and robust fault diagnosis for a class of nonlinear system: Detectability analysis[J]. Computers and Chemical Engineering, 2004, 28(12): 2635-2646.
- [8] Janos Gertler. Analytical redundancy methods in fault detection and isolation[C]. Proc of IFAC/ IMACS Symposium on Fault Detection, Supervision and Safety for Technical Processes. Baden-Baden: Pergamon Press, 1991.
- [9] Iri M, Aoki K, O'Shima E, et al. An algorithm for diagnosis of system failures in the chemical process[J]. Computers and Chemical Engineering, 1979, 3(1/2/3/4): 489-493.
- [10] Wu J D, Wang Y H, Mingsian R B. Development of an expert system for fault diagnosis in scooter engine platform using fuzzy-logic inference[J]. Expert Systems with Applicatio, 2007, 33(4): 1063-1075.
- [11] Venkatasubramanian V, Rengaswamy R, Yin K, et al. A review of process fault detection and diagnosis: Part I[J]. Computers and Chemical Engineering, 2003, 27(3): 293-311.
- [12] Venkatasubramanian V, Rengaswamy R, Yin K, et al. A review of process fault detection and diagnosis: Part II[J]. Computers and Chemical Engineering, 2003, 27(3): 312-326.
- [13] Venkatasubramanian V, Rengaswamy R, Yin K, et al. A review of process fault detection and diagnosis: Part III[J]. Computers and Chemical Engineering, 2003, 27(3): 327-346.
- [14] 侯忠生, 许建新. 数据驱动控制理论及方法的回顾和展望[J]. 自动化学报, 2009, 35(6): 650-667.
(Hou Z S, Xu J X. On data-driven control theory: The state of the art and perspective[J]. Acta Automatica Sinica, 2009, 35(6): 650-667.)
- [15] 周东华, 胡艳艳. 动态系统的故障诊断技术[J]. 自动化学报, 2009, 35(6): 748-758.
(Zhou D H, Hu Y Y. Fault diagnosis techniques for dynamics systems[J]. Acta Automatica Sinica, 2009, 35(6): 748-758.)
- [16] 方崇智, 萧德云. 过程辨识[M]. 北京: 清华大学出版社, 1988.
(Fang C Z, Xiao D Y. Process identification[M]. Beijing: Tsinghua University Press, 1988.)
- [17] Wang H, Chai T Y, Ding J L, et al. Data driven fault diagnosis and fault tolerant control: Some advances and possible new directions[J]. Acta Automatica Sinica, 2009, 35(6): 739-747.
- [18] Camil Fuchs, Ron S Kenett. Multivariate quality control: Theory and application[M]. New York: Marcel Dekker, 1998.
- [19] Necip Doganaksoy, Frederick W Faltin, William T Tucker. Identification of out of control quality characteristics in a multivariate manufacturing environment[J]. Communications in Statistics-Theory and Methods, 1991, 20(9): 2775-2790.
- [20] Montgomery D C. Introduction to statistical quality control[M]. New York: John Wiley and Sons, 1985.
- [21] Page E S. Continuous inspection schemes[J]. Biometrika, 1954, 41: 100-115.
- [22] Jolliffe I T. Principal component analysis[M]. New York: Springer, 2002.
- [23] Jackson J E. Quality control methods for several related variables[J]. Technometrics, 1959, 1(4): 359-377.
- [24] Jackson J E, Mudholkar G S. Control procedures for residuals associated with principal component analysis[J]. Technometrics, 1979, 21(3): 341-349.
- [25] Miller P, Swanson R E, Heckler C E. Contribution plots: A missing link in multivariate quality control[J]. Applied Mathematics and Computer Science, 1998, 8(4): 775-792.
- [26] Carlos F Alcala, Joe Qin S. Reconstruction-based contribution for process monitoring[J]. Automatica, 2009, 45(7): 1593-1600.
- [27] Richard O Duda, Peter E Hart. Pattern classification and scene analysis[M]. New York: Wiley, 1973.
- [28] Raih A C, Cinar A. Statistical process monitoring and disturbance isolation in multivariate continuous processes[J]. AIChE J, 1996, 42(4): 995-1009.
- [29] Pail Nomikps, John F MacGregor. Monitoring batch processes using multiway principal component analysis[J]. AIChE J, 2004, 40(8): 1361-1375.

- [30] Scholkopf Bernhard, Smola Alexander, Muller Klaus-Robert. Nonlinear component analysis as a kernel eigenvalue problem[J]. Neural Computation, 1998, 10(5): 1299-1319.
- [31] Müller K R, Mika S, Rätsch G, et al. An introduction to kernel-based learning algorithms[J]. IEEE Trans on Neural Networks, 2001, 12(2): 181-201.
- [32] Kramer Mark A. Nonlinear principal component analysis using autoassociative neural networks[J]. AIChE J, 1991, 37(2): 233-242.
- [33] Leo H Ciang, Evan L Russell, Richard D Braatz. Fault diagnosis in chemical processes using fisher discriminant analysis, discriminant partial least squares, and principal component analysis[J]. Chemometrics and Intelligent Laboratory Systems, 2000, 50(2): 243-252.
- [34] Paul Geladi, Bruce R Kowalski. Partial least-squares regression: A tutorial[J]. Analytica Chimica Acta, 1986, 185: 1-17.
- [35] Sijmen de Jong. SIMPLS: An alternative approach to partial least squares regression[J]. Chemometrics and Intelligent Laboratory Systems, 1993, 18(3): 251-263.
- [36] Ku W, Storer R H, Georgakis C. Disturbance detection and isolation by dynamic principal component analysis[J]. Chemometrics and Intelligent Laboratory Systems, 1995, 30(1): 179-196.
- [37] Leo H Chiang, Russell E L, Braatz R D. Fault detection and diagnosis in industrial systems[M]. London: Springer, 2001.
- [38] Drif M'hamed, Benouzza N, Kraloua B, et al. Squirrel cage rotor faults detection in induction motor utilizing stator power spectrum approach[C]. Proc of Int Conf on Power Electronics, Machines and Drives. London: IET, 2002: 133-138.
- [39] Nandi S, Toliyat H A. Fault diagnosis of electrical machines-a review[C]. Proc of IEEE Industry Applications Conf. Piscataway: IEEE, 1999: 219-221.
- [40] Grossmann A, Morlet J. Decomposition of Hardy functions into integrable wavelets of constant shape[J]. SIAM J Mathematic, 1984, 15(4): 723-736.
- [41] Lopez J E, Tenney R R, Deckert J C. Fault detection and identification using real-time wavelet feature extraction[C]. Proc of the IEEE-SP Int Symposium on Time-Frequency and Time-Scale Analysis. Piscataway: IEEE Press, 1994: 217-220.
- [42] Marco Ferrante, Bruno Brunone. Pipe system diagnosis and leak detection by unsteady-state tests[J]. Advances in Water Resources, 2003, 26(1): 107-116.
- [43] Rolf Isermann. Model based fault detection and diagnosis methods[J]. Annual Reviews in Control, 2005, 29(1): 71-85.
- [44] Isermann R, BalléP. Trends in the application of model based fault detection and diagnosis of technical processes[J]. Control Engineering Practice, 1997, 5(5): 709-719.
- [45] Isermann R, Freyermuth B. Process fault diagnosis based on process model knowledge: Part I[J]. J of Dynamic Systems, Measurement and Control, Transactions of the ASME, 1991, 113(4): 620-628.
- [46] Stockwell R G, Mansinha L, Lowe R P. Localization of the complex spectrum the S transform[J]. IEEE Trans on Signal Processing, 1996, 44(4): 998-1001.
- [47] 王成栋, 张优云, 夏勇. 基于 S 变换的柴油机气阀机构故障诊断研究[J]. 内燃机学报, 2003, 21(4): 271-275.
(Wang C D, Zhang Y Y, Xia Y. Fault diagnosis for diesel valve train based on S transform[J]. Trans of CSICE, 2003, 21(4): 271-275.)
- [48] Livanos G, Ranganathan N, Jiang J. Heart sound analysis using the S transform[J]. Computers in Cardiology, 2000, 27: 587-590.
- [49] Huang N E, Shen S S. Hilbert-huang transform and its applications[M]. Singapore: World Scientific Publishing Co. Pte. Ltd, 2005.
- [50] Peng Z K, Peter W Tse, Chu F L. A comparison study of improved Hilbert-Huang transform and wavelet transform: Application to fault diagnosis for rolling bearing[J]. Mechanical Systems and Signal Processing, 2005, 19(5): 974-988.
- [51] Chow M Y, Mangum P, Thomas R J. Incipient fault detection in DC machines using a neural network[C]. Proc of the 22nd Asilomar Conf on Signals, Systems and Computers. San Jose: IEEE Press, 1988: 706-709.
- [52] Krzysztof Patan, Marcin Witczan, Józef Korbicz. Towards robustness in neural network based fault diagnosis[J]. Int J Application Mathematical Computer Science, 2008, 18(4): 443-454.
- [53] Zhao J, Chen B, Shen J. A hybrid ANN-ES system for dynamic fault diagnosis of hydrocracking process[J]. Computers and Chemical Engineering, 1997, 21(20): 929-933.
- [54] Cristianini N, Shawe-Taylor J. An introduction to support vector machines and other kernel-based learning methods[M]. Cambridge: Cambridge University Press, 2000.
- [55] 谢芳芳. 基于支持向量机的故障诊断方法[D]. 长沙: 湖南大学电气与信息工程学院, 2006.
(Xie F F. Support vector machine for fault diagnosis[D]. Changsha: College of Electrical and information Engineering, Hu'nan University, 2006.)