

# 华中科技大学

## 本科生毕业设计（论文）参考文献译文本

译文出处： Reis M S, Gins G. Industrial Process Monitoring in the Big  
Data/Industry 4.0 Era: From Detection, to Diagnosis, to  
Prognosis[J]. Processes, 2017, 5(3): 35.

院 系                      机械科学与工程学院

专业班级                      机械 1401 班

姓 名                      张照博

学 号                      U201410606

指导教师                      金海、吴波

2018 年 1 月

## 译文要求

- 一、译文内容须与课题（或专业内容）联系，并需在封面注明详细出处。
- 二、出处格式为  
图书：作者. 书名. 版本（第×版）. 译者. 出版地：出版者，出版年. 起页～止页  
期刊：作者. 文章名称. 期刊名称，年号，卷号（期号）：起页～止页
- 三、译文不少于 5000 汉字（或 2 万印刷符）。
- 四、翻译内容用五号宋体字编辑，采用 A4 号纸双面打印，封面与封底采用浅蓝色封面纸（卡纸）打印。要求内容明确，语句通顺。
- 五、译文及其相应参考文献一起装订，顺序依次为封面、译文、文献。
- 六、翻译应在第七学期完成。

## 译文评阅

---

### 导师评语

应根据学校“译文要求”，对学生译文翻译的准确性、翻译数量以及译文的文字表述情况等做具体的评价后，再评分。

评分：\_\_\_\_\_（百分制）      指导教师（签名）：\_\_\_\_\_

年    月    日

“大数据” 结合 “工业 4.0” 的工业过程监测：  
从检测到诊断到预测故障

**Marco S. Reis<sup>1,\*</sup> and Geert Gins<sup>2</sup>**

1. CIEPQPF-Department of Chemical Engineering, University of Coimbra Polo II, Rua Sílvia Lima 3030-790, Coimbra, Portugal<sup>[1]</sup>; AIXIAL Belgium, Charleroi Steenweg 112, B-1060 Brussels, Belgium; geert.gins@icloud.com
2. \* Correspondence: marco@eq.uc.pt; Tel.: +351-239-798-727

Academic Editors: Leo H. Chiang and Richard D. Braatz<sup>[2]</sup> Received: 1 June 2017; Accepted: 27 June 2017; Published: 30 June 2017

### 【摘要】

我们今天要讨论的是工业过程检测 IPM（工业过程检测，**Industrial Process Monitoring**）产生 100 年来的一次决定性的变革。下面我简要介绍了长期以来 IPM 发展的几种演变趋势，主要集中在数据驱动方法上。我们也会证明除了这些趋势，研究重点也在演变。IPM 初期阶段的重点是优化 IPM 检测性能，但是近来故障根源分析以及诊断变得越来越重要，并且由此诞生了几种不同的方法来扩大 IPM 的这个新的而且重要的方向。我们认为在将来工业过程检测的另外一个重要的方向是预测维护。在这一方面又提出了一些有关于过程监测和设备维护部门之间的强互作用的观念。

**【关键词】** 工业过程监测；故障检测与诊断；预测；过程健康；设备健康

## 1. 工业过程监测的新趋势

随着工业 4.0 的出现以及大数据兴起的势头，制造业遇到了使其性能达到新高，在关键技术方面实现突破的机会。从产业运营，经济和市场方面到过程安全和环境问题等，性能这一概念都被广泛地采用。关键因素（图 1）是：

- (i) 数据；
- (ii) 技术
- (iii) 分析

事实上，现在数据比以往任何时候都多，而且它们积累的速度正在加快：根据 IBM 的说法，现在有 1.6 Zetabytes（1021 字节）的数字数据可用，而且这个数字还在增加。这种数据洪流完全会因为随着更多、更好的信息传感技术的发展，我们能够收集到更多来源的信息，以及储存在综合的数据库中，并且随时取用而实现。目前也存在使用高级分析平台（第三方平台）处理大量数据所需的计算资源（高性能计算，云服务，分布式和并行计算等），并在这些数据仍有价值的时候将其转化为可操作的信息。

在各种职能和组织层面上使用这三种关键推动力因素的压力正在迅速增加。迄今为止，这种现象在大公司之内尤为明显，但是中小企业也应该竭力参与这一过程。目前，所有机构的学习和适应能力正在受到考验，而上面所说的这三种关键推动力因素正在成为有效的竞争优势来源。




图 1-1 大数据环境下的三种推动力

自从 1920 年 Walter A. Shewhart 的开创性工作至今，作为工业企业中的核心职能，流程监控必然遵循将“数据/技术/分析”三种技术综合与近 100 年中所有发展出来的理论知识

和实践经验相结合这一路线。工业过程监测（IPM）是世界各地公司中具有核心重要性的内容。IPM 使得他们能够达到更高的安全水平，获得更高水平的效率，质量，盈利能力和环境管理绩效，这对全世界公司来说是至关重要的。

IPM 自从推出以来的发展历程的回顾分析清楚地表明，在 IPM 难以适应新的和更苛刻的应用场景的特点，难以处理来自益复杂的流程的数据结构的特点下，我们一直在为适应新的和更苛刻的应用场景而不断努力。在接下来的小节中，将介绍一些由于日益复杂的流程而导致的难以处理的数据结构以及简要介绍了 IPM 近十年来的简单（而不是那么容易）的可见的趋势，其中甚至包括了一个可能引导未来的 IPM 发展革命的趋势。

### 1.1 从单一到多元，到多维（海量）数据

随着从传感器和数据采集系统收集到的来自过程检测单元和数据流（例如，温度，流速，压力，pH，电导率等）的信息其可用性的增加，最初开发出来的单变量方法迅速演变为多变量方法，然后出现了海量数据的框架，不仅能够应对规模，而且还能处理典型的数据丰富场景的高度共线性问题。这是 IPM 的一个古老而成熟的趋势，不需要进一步的介绍，因为它在过去 20 年的研究和评论文章中得到了广泛的讨论。

### 1.2 从同构数据表到异构数据集

计量和传感技术的发展导致了谱图，高光谱图像，联用数据，色谱图，粒度曲线，粒度分布，轮廓数据等新的“变量”类型的出现。这极大的促进了专用解决方案的发展，并将轮廓监测作为 IPM 的一个新领域出现。IPM 历史上的主要由过程传感器和单变量变量测量组成的均质数据源现在正在升级，它们都是在每个采样时间采集标量值（即所谓的标量传感器）（一阶张量），灰度图像（二阶张量），高光谱图像（三阶张量），联用变量（ $n$  阶向量， $n \geq 2$ ）等高阶向量组成的各种数据结构，称为向量传感器）。目前工业数据的这种异质性，正是 IPM 范围内大数据变化维度的反映。

### 1.3 从静态到动态到非静态

与现代仪器提供的高采样率有关的工业现象的惯性特征导致所收集的数据中出现自相关模式。传统的过程监控方法被设计为在静态平稳过程中采集到独立和相同的分布随机变量的假设下运行，包括所有类型的控制图和多变量概括，如 Hotelling 的  $T^2$  控制图和多变量基于主成分分析（PCA-MSPC）的统计过程控制。但是这些变量必须升级，使得其适应动态过程。目前提出了几种类型的解决方案来处理连续生产系统中自相关的存在，如下：

(i) 调整监控图的控制限度 - 限于单变量过程的解决方案，具有非常简单的动态性(例

如单变量一阶自回归过程）；

(ii) 使用从正常运行数据估计的动态模型结构来监视一步预测残差，例如；时间序列，状态空间（例如，通过典型变量分析）或动态潜在变量模型；

(iii) 实施将自相关矩阵对角化的变量变换，如在多尺度统计过程控制中所发生的那样；这种方法还可以处理多尺度动力学和复杂干扰的设备。

最近，解决非平稳动力学问题的需求变得越来越重要，因为批量工艺现在正在宣告应该注意到它们在工业系统（半导体，化学，制药，食品等）中无处不在这一现象。这些过程本质上是非平稳的，可能呈现出几个阶段，这些特征给他们的监测带来了重大的挑战。为这一重要的过程开发的解决方案包括双向和三向多变量方法，动态方法和面向特征的方法。

#### 1.4 从均值到散列和相关

过程监测的单变量方法密切关注所监测的过程变量的均值和离差的变化。然而，当转向多元高维应用时，我们越来越聚焦于对过程平均水平的分析上。比如 Hotelling 的  $T^2$  控制图以及用于高维度监控的潜在变量方法。事实上，即使 PCA-MSPC 通常被认为能够检测变量相关结构的变化，即通过  $Q$  或 SPE（平方预测误差）统计，但是仔细观察就可以发现这样的灵敏度可能很低，这种方法很依赖于过程监测的水平。另一方面，现代工业过程的共同特征是存在控制回路和先进的监控平台，这些装置分布在所有的单位上，并通过级联方案在几个监管层组织起来。这种调节机构试图通过给不可控变化源补偿一些输入变量（称为控制群中的负载变量）将目标变量调节到设定点。当发生故障时，控制回路试图维持目标变量的变化水平，削弱导致过程紊乱的因素。因此在实践中，由于控制回路的有效作用，过程故障对于变量水平的影响不是那么强烈。然而，变量之间的相关性确实发生了显著变化，因为测量过程中的变量之间的相互作用受到了故障的干扰。在这些条件下，有充分的理由期待并相信监控过程相关结构，特别是小粒度的相关结构（部分相关性），将会增加过程异常检测的灵敏度，并改善诊断监测方法的能力。Rato 和 Reis 紧随其后，另见胡旺、Sullivan 等人和其中的参考资料。

#### 1.5 从非结构化到结构化过程监控

任何过程监控活动的基础都是正常操作条件（NOC）的模型。经典的 NOC 模型包括高斯，二项式，泊松，潜变量，具体的模型取决于监测对象。同时我们也采用非参数方法来处理传统的 NOC 模型。这些方法的参数是使用 NOC 数据估算的，从这些数据可以确定控制极限。但是，过程数据并不是所监控系统的唯一信息来源。有关过程的背景知识，根据某些过程单元，

过程流程表等基本原理建立的精确机械模型的存在构成了可用信息的额外来源，在 NOC 下运行的任何过程都必须遵守这些机械模型。换句话说，它们代表了在正常条件下运行的过程的限制条件。通过在监测程序中包含这些限制条件，将更多的真实系统纳入 NOC 描述中。这可能有两个有趣的结果：

(i) 由于 NOC 模型所带来的更完整的描述是切实存在的，所以应该有可能检测到更精细的偏差，即增加监视灵敏度：

(ii) 使用此类附加信息还将提高过程诊断和故障排除的有效性，超越仅使用 NOC 数据可能实现的效果。后者的后果值得更详细的检查。对 NOC 数据的性质进行更仔细的分析表明，它是非关联的（或非关联性的）。

事实上，收集和用于过程监测的数据只反映了正常的操作条件——使用 Fisher 的术语，它由“偶然”数据组成，因此是非因果性的。从这些数据构建的模型，如高维过程的主成分分析（PCA）或偏最小二乘法（PLS），将因此被限制在非因果关系的描述中。它们不包含完整诊断和故障可分离性的关键因素：因果关系。这就是为什么当“询问”哪些变量是对监测统计量的变化影响最大的因素时（贡献图分析的目的），这些方法必然会提出一组与变化起源相关的变量用来区分哪些变量是故障原因，哪些变量是结果。这导致众所周知的拖尾效应。这是传统“非结构化”方法的一个限制性特征，可以通过在 IPM 方法中引入更多因果关系结构或先验过程知识来避免。

## 1.6 文章内容和贡献总结

前面几部分提出的趋势突出表明了 IPM 在历史上一直面临的收集数据和原因生成机制（过程）日益复杂的问题。传统的监测方法已经不能适应大多数当前的工业应用场景，还有一些挑战还有待解决。比如：处理数据量不断增加，整合多尺度和非平稳动态，融合异构数据结构，整合处理与数据相关的知识，监控相关结构等。在 IPM 挑战的数量和相关性逐步增加的背景下，IPM 成为了工业运营中最有趣的领域之一，是短期内亟待解决方案的领域之一。

然而，IPM 的研究重点也正在发生战略性变化。早期的特点是统一都是致力于减少故障发生和检测之间所花费的时间。多年来，这是过程监测的主要考虑因素，为了提高检测性能，特别是速度提出了许多方法。目前，无论是因为这个问题被大量的情况所掩盖，还是由于对整个 IPM 周期而不是仅仅第一阶段的有效性的认识不断提高，这种情况正在发生变化。实际上，在实践中寻找典型的 IPM 周期，我们可以很容易地注意到，就其检测速度而言，好的方法和最好的方法之间的差别通常是几秒，最长的也就几分钟。然而，检测后的 IPM 周期的后



续阶段，即诊断，通常需要数小时至数天才能成功完成。因此，过程停机时间主要由诊断阶段决定，而检测阶段通常只是其中的一小部分。因此，如果应用于改善故障诊断而不是以相同的相对量减少检测时间，则我们可以减少停机时间。这些情况使得我们将更多的注意力转向故障诊断，并且在这方面出现更多的 IPM 方面贡献。

然而我们认为在未来随着工艺效率，安全性，环境性能和经济周转率等标准的不断提高，再加上“工业 4.0”所带来的新技术资源，IPM 不会止步于此。此外，我们相信下一步是开发具有系统故障预测能力的工具：故障预测系统。当然，在 IPM 的三个主要阶段（检测，诊断和预测）中总是有活动的空间。这是跟上工业流程不断演变所带来的挑战的必要条件。然而从诊断和预测故障方法的现状可以预见的是会经历极大地扩张。

IPM 演化的这三个时刻将在第二部分，第三部分和第四部分进行讨论。将特别强调现在（诊断），以及未来（预测性维护）。在第五节中，我们进一步阐述了本文的内容，并在最后的总结上作了总结。



## 2. 研究重点 - 过去：检测

如介绍部分所述，IPM 已经经历了多种趋势，反映了需要适应越来越复杂的过程监测和处理数据的情况。因为挑战变得更加严峻，这一努力的主要重点是尽可能实现最佳的检测性能，包括主流的单变量和多变量统计过程监控方法。这些方法基于采用某种足够灵活的概率模型结构来描述广泛的工业过程的 NOC（正常操作条件，Normal Operating Conditions）行为。除了在第一阶段分析期间从过程数据获得的 NOC 模型的参数估计以外，这些通用的方法通常不需要关于过程结构的特定信息。例如著名的基于 Univariate i.i.d 高斯模型的肖哈特（Shewhart）指数加权移动平均（EWMA）以及累积和（CUSUM）控制图，这一方法可以利用样本均值作为中心极限定理的结果，将其用于一大类静态过程。同时也包括他们的多变量扩展，即考虑 NOC 行为符合  $n$ -dimensional i.i.d 高斯过程（即 Hotelling's  $T^2$  chart），多元指数加权移动平均图（MEWMA）和多元累积和图（MCUSUM），以及基于 PCA 和 PLS 的高维度方法。后两种方法属于一类潜变量监测方法，在学术界和工业界都取得较高的成功和接受度。它们的模型结构呈现的元素与正常条件下工业过程的本质更加一致。图 2 给出了在多变量和潜变量过程监控方法中隐含的模型结构，其非因果性和假定的内在机制明确。特别的，多变量方法默认了可变性驱动因素是可观察的，并且这些因素之间表现出不同程度的相关性。另一方面，潜在变量框架假设所收集测量的观测差异性是由一些基本的和不可观测的数量驱动的，这些数量是它们变化的原因（如原材料，环境条件，机器，操作员等）。最后的描述与在 NOC 情景下工作的工业单位发生的事情非常相似，这使得我们采用潜在变量工具来处理这些环境中的问题。




图 2-1 基础模型结构的图解说明：  
(a) 经典的多元方法 (b) 潜在变量方法

变量和属性的许多其他统计过程监测方法属于这一类，为处理工业过程的动态的、多尺度的、非高斯的和非线性的性质而开发的其他更先进的技术也归于此类，但是超出本文的范围提供所有的详尽介绍，所以就不做多讲。

以上提到的所有方法都是为了适应日益复杂的过程和数据而开发的，它们的性能基本上是以检测度量来表征的，这证实了 IPM 过去的重点。主要的检测性能指标是检测速度和检测强度。

检测速度是指在发生异常后及时或迅速地发出异常。通常通过观察一个给定类型的异常事件和一个给定的幅度所需的观察次数来评估平均时间。通常用于表征检测速度的因素是平均运行长度（ARL）或相关数量信号平均时间（ATS）。最近还提出了其他措施，如条件预期延迟（CED），它表示在故障发生之前没有发出误报的情况下的平均检测延迟。

检测强度与正确检测异常情况的能力有关，不会产生过多的误报。通常采用的品质因数是良品率（TPR），也被称为正确检测率（TDR）。有时还会使用检测错误率（也称为整体 II 型错误）（MDR = 1 - TPR），特别是重点是没有检测到的错误的时候。TPR 也被称为这一检测方法的灵敏度，其计算取决于用于建立监测条件的显著性水平。显著性水平对应于假阳性率（FPR，又名假警报率，FAR 或总体类型 I 错误）。因此，在计算 TPR 时，必须设置 FPR 参数为常量。而且，基于 FPR 的 TPR 的检测方法之间的比较必须要 FPR 是相同的才行。

实现高水平的检测速度和强度是过去 IPM 研究的主要重点。在处理新流程时，这是一个必要的步骤，但是在这个阶段，越来越多的因素阻碍了更先进的监控手段的发展。因此为了解决这些障碍与挑战，我们需要找到一种方法可以找到故障根源，这就是：过程诊断

### 3. 研究重点 - 现在：诊断

前面提到的 IPM 方法中使用的 NOC 模型包含一个很有趣的故障检测特性，即鲁棒性，高效性（灵敏度）和简单性。但是，在处理 IPM 的下一阶段——诊断时，会出现一些局限性。

其中一个局限性是它们内在的非因果性（或非因果性）的直接后果。当目标是故障检测时，第 2 节介绍的 IPM 方法的 NOC 模型的非因果特性并不是主要的问题，因为通常现有的模型足以评估新的观测数据是否落入 NOC 模型的范围内。这个表层特性包含了 NOC 的变化性，可以根据平均变量的水平和它们之间的主要联系来推导出来。但是，诊断需要更多的信息才能正确执行。这项活动要求了解系统中传播的因果方向性。只有利用这些信息，才有可能回溯并找出哪些变量可能与观察到的异常效应的起源有关。这种因果结构在重点检测方法中是缺乏的，当用于这一目的时可能导致模糊的诊断：PCA-MSPC 范围内的贡献图中的拖尾效应是 PCA 的非因果性质的直接后果。

为了规避传统的面向检测的方法的这种局限性，近来已经开发了几种方法，将更多的关于 IPM 中的过程因果连通性结合起来，不仅改进检测，而且主要是为了解决故障诊断中的问题。这些“结构化”的方法（以这种方式命名，是因为它们将过程特定的结构纳入其算法中）可以根据因果关系信息的来源分类为基于知识的数据驱动。

基于知识的结构化方法利用原有的知识或有关过程的因果连通性的信息。这种先验知识可以转化为定性或半定量的 NOC 模型，从而为 IPM 带来过程特定的因果信息，从而可以进行诊断和故障排除。例如，在几乎所有的工业过程中通常可以获得的知识之一是过程流程表和构成工厂的多个处理单元的流程图概要。这些图表显示了所有相关的设备，连接它们的管道以及信息如何从传感器流向控制器到执行器。从这些过程图的分析中，可以很容易地建立因果关系的方向，并将其转化为计算机可识别的代码，以便整合到 IPM 中。编写这些信息的一种方法是通过因果图。纳入过程因果结构的其他定性和半定量的描述包括键合图，带权有向图（SGD），平价关系，灰箱模型和贝叶斯网络。

另一方面，数据驱动的结构化方法直接从过程数据库中的可用的大量历史记录中提取出特定于过程的信息以进行故障诊断。在大数据和工业 4.0 时代，这种结构化的 IPM 方法特别有利于扩大大数据的应用范围，并且在多样性和重要性方面有了长足进步。为此，我们将通过在接下来的两个小节中提到使用特定于过程的信息进行过程诊断的不同观点来更多地关注这种类型的结构化 IPM 方法，即：

1) 网络推理结构化方法 (NISA)

2) 基于分类的方法 (CBA)

### 3.1 数据驱动的过程诊断结构化方法：网络推理结构化方法 (NISA)

这类数据驱动的结构化方法只需要访问可用的 NOC 数据。例如，Bauer 等人使用传递熵来识别故障传播路径的方向性，从而更好地把过程紊乱的根本原因隔离出来。另外，时间延迟分析也可以用于相同的目的。另一方面，Yuan 和 Qin 将 PCA 的格兰杰因果联合起来对具有振荡特征的故障进行特征选择，确定出高概率的模块可能包含着故障的根本原因。

部分相关也是一个连接各个观察变量的直接关系网络的可行方案。因此，它们有可能被并入到有效的数据驱动的结构化 IPM 方法中去。在此背景下，Rato 和 Reis 研究出来了敏感性增强转换 (SET) 类，这是一种基于部分相关性的解决方案，已经成功应用于过程监测。应用程序包括离线和在线模式，静态、动态、多变量（多维）处理过程，同样也有类似的检测、诊断程序。简而言之，该方法使用建立的去相关变换来预处理所监视的变量的集合。去相关变换是考虑到观察到的变量之间的因果关联而建立的。这些因果关系源于基于使用偏相关和时间序列分析网络推理算法。去相关变换主要包括为每个变量建立一个预测回归模型作为其因果来源的函数，然后用它来计算变量残差。其余残留的关联因果关系用 Cholesky 转换去除。然后可以使用传统的监测统计来监测解相关的变量，如 Hotelling 的  $T^2$ 。

### 3.2 数据驱动的过程诊断结构化方法：基于分类的方法 (CBA)

基于分类的方法 (CBA) 在对数据资源的要求方面要求更高：它们假设存在过程故障的标记数据集，而不是仅仅访问 NOC 数据，就像 NISA 方法那样。因此，NISA 和 CBA 代表执行数据驱动故障诊断的两种不同方式：NISA 从 NOC 数据推断因果关系；CBA 使用以前的故障数据来辅助诊断未来的不适。在这种情况下，CBA 方法的一个明显局限是这种标记的异常事件数据集的可用性。虽然有着这一局限，但是随着数据的不断积累，满足这一要求的情况往往会增加，使之成为一些场景下运行过程检测时的可行选择。此外，分类方法可以适应于识别前所未见的过程故障。在这种情况下，故障识别可以委托给处理专家。一旦收集到足够数量的新的故障例子，CBA 模型就可以被扩展或重新训练以识别新类型的过程扰动。

开发这一类方法的主要动机也源于在多元场景中进行故障诊断的流行工具中存在的限制。例如，使用贡献图是在基于 PCA 的过程监控方法中进行故障识别的常用方法。他们指出

哪些变量表现出不同于正常操作的行为，而不需要任何先验信息。将信号变量与根本原因联系起来的最后阶段留给故障诊断专家。然而，这是一个复杂的任务，特别是对于复杂的故障诊断。此外，故障拖尾本身就存在于所有类型的贡献中，并且可能导致错误的诊断。在这种情况下，如果已知过程故障的历史数据库可用，故障识别可以转化为分类问题，并且可以使用多种机器学习方法来促进根本原因的分析。这个想法很简单：根据故障传感器和执行器的每个故障的指纹模式，训练分类模型以区分所有可能的故障类型；然后，在监测过程中，分类器根据这个参考库评估每个检测到的异常，并将其分配给它最相似的类别。

在基本过程监控中，依次进行故障检测和识别：首先检测过程干扰，然后识别其根本原因。这种方法通常是由传统的过程监测的研究人员所遵循的。然而，故障分类模型使得能够同时检测和识别过程干扰，仅仅通过在分类器中包括“正常操作”作为额外类别。这种方法在机器学习背景的研究团队中更为常见，例如 Yu、Lazzaretti、Jing 和 Hou 等人采用这种方法。

但是，这种看似简单的方法也提出了一些需要解决的实际问题。故障检测和识别所面临的第一个问题是，由于难以获得足够的故障的例子，所以正常操作类和一个或多个故障类之间通常存在很大的数据的不平衡。这对大多数多分类器来说是一个重大的挑战。一类分类器（用一个单独的模型描述每个数据类的特征）对类不平衡兼容性更高，因为它们一次只考虑一个类，但是基于密度的方法（高斯混合模型，Parzen 模型等）仍然需要足够数量的样本来正确估计样本密度并为每个类别构建有实际意义的边界。

第二个问题是分类器为每个错误分类分配相同的权重。在故障诊断系统支持操作员操作但尚未用于直接控制过程（例如化学或制药行业）的行业中，正确的故障检测可能比正确的分类重要得多。用于同时检测和识别的分类器需要特定类别的参数（例如每个故障类别的不同错误分类成本）来处理这些不对称的性能要求。随着引入更多的参数，故障分类模型的识别变得更加复杂，并且同时故障检测和识别的数学表达式的简单性就不存在了。Gins 等人提供了这个问题的解决方案。相反，顺序方法一直允许故障检测和故障识别之间侧重点不同这一特点。

我们认为，在很多情况下，顺序故障检测和识别方法比同步方法显示出显著的优势。然而，在一系列广泛的基准测试中，从来没有对同时性和顺序性故障检测和识别的性能进行精确的量化。

另一类基于分类框架的故障诊断方法是基于变量选择方法的方法。根本的原则是：当发

生故障时，并不是所有的变量都同时发生变化。只有一部分过程变量出现一个重要的变化。因此，通过隔离这组变量，可以减少可能的故障搜索空间，加快故障排除过程。变量的选择通过在检测到故障之前和之后实施分类方法来完成，并分析用于分离这两个类别的最有区别的变量。关于这一类方法的更多信息可以在 Wang 和 Jiang 和 Zou 等人的著作中找到。



#### 4. 研究重点 - 未来：预测

一旦检测和诊断的解决方法和方法变得稳定并且可以被流程所有者所接受，从我们的角度来看，IPM 发展（未来）的下一个逻辑阶段将是一个预测性维度的整合：故障预测。随着时间的推移，操作风险的演变的知识成为非常有价值的战略资产，因为它可以更好地规划维护和关闭操作，最大限度地减少生产损失，同时确保人员和设备的安全。与此同时，更好地管理流程目标和操作风险会带来经济效益，但实际上又如何实现呢？有一些办法可以使这一努力成为现实。下面我们就可能的发展路线来分享一些想法来解决这个问题。

随着工业 4.0 和大数据的出现，结构化和非结构化数据将越来越多地从过程监测的各个角度提供。过程监测和产品质量数据库已被整合到过程监控，控制和优化的预测性维护中。软传感器和推理模型就是这方面使用的工具的例子。然而，很奇怪的是，大多数面向流程的开发人员都忽略了一个数据库：维护部门数据库。这种资源积累了工厂所有设备的故障，在这种情况下，一个合理的猜测是设备故障行为可能与他们在服务期间遭受的情况有关。因此，通过对过程监测和维护数据库进行跨越联合，可以获得关于操作条件对系统可靠性影响的关键信息，从而最终为流程改进提供见解，并为操作风险管理提供风险预测。

在 Shewhart 的“普遍原因”/“特殊原因”系统化的框架下进行分析时，预测可能看起来是矛盾的，特殊原因是自然界不可预测的。Shewhart 的观点以及主流统计过程控制（SPC）/工业过程监测（IPM）社区的观点都集中在“过程健康”（如预期的那样 - 注意两个名称中均存在“过程”一词）。然而，预测与“设备健康”（设备性能随时间的演变）密切相关，根据这一推论可以对操作有效性和故障率作出推断。因此，IPM 和可靠性和维护（R&M）等学科的近似估计会造福预测性维护的发展，我们认为这种相互作用在即将到来的时代还有很多。

前面提到的 IPM / R&M 的整合将不仅有利于过程监控，而且从制造工艺单元全球优化的条件的角度出发，也有利于（并且非常重要的）以过程监测为导向的目标（生产吞吐量，选择性，产品质量）和可靠性指标（服务时间，停机时间，故障间隔时间，故障率）的进步。两者对公司的全球业绩都有决定性的影响，不能（不应该）分离（如过去所做的那样），也就是不重叠并且单独的对工作流程来处理。

#### 5. 讨论和最后的备注

在这篇文章中，我们几乎对 100 年前从事工业活动开始就形成得 IPM 发展的几个趋势进



行了讨论，同时对在这个漫长的时期内不断变化的研究重点，从检测，故障诊断到预测性维护也进行了论述。第二部分以早期发现的过程故障（过去）着手来着重介绍了早期对统计过程监测的重点。那时候平均运行长度（ARL）和平均信号传播时间（ATS）等指标是首选的性能指标，尽管它们在当下时代有其局限性。

然而，监控的最终目标是确保人员和资产的安全运行，并尽可能减少整个过程的停机时间，其中检测时间通常只是一小部分。在这方面，更重要的是诊断和排除故障所花费的时间，直到问题的根本原因被独立出来并且进行评估，并据此决定是否继续作业或立即关闭。在这方面，已经提出了一些工具和程序来促进和缩小这个时间。这是第3节（现在）的范围，其中的方法，如由Mason等人提出的T2分解在使用主成分分析（PCA）和偏最小二乘（PLS）模型进行高维过程监测的背景下，多变量统计过程监测和贡献图方法是众所周知的对故障重要性诊断的手段。前一种方法受到Hotelling的T2方法学的应用范围的限制，通常限制在10-15个以下的过程变量，并涉及与所监测的变量的数目不利地组合的复杂性。另一方面，后一种方法确实是相当快速和简单的，通常会提出有关问题的有用信息。但是，它也会出现一些不良的特征，如“拖尾效应”，即一个变量的故障会影响与其相关的所有变量的贡献，从而降低诊断过程的有效性。正如第1.5节所述，这些限制可以通过IPM方法论得到恰当的解决，这些方法论能够将更多的过程特定的因果关系结构纳入其数据库中。

第四部分介绍了我们认为IPM的下一阶段的发展趋势：预测性维护。有了它，IPM将获得一个预测功能，可以更好地管理流程和关键资产。以前只是假设存在但不处理的一些不平稳现象将被明确地建模并整合到IPM程序中。这包括设备磨损，结垢，失活，腐蚀，老化等。方法既可以是数据驱动的，也可以是基于模型的，或者两者兼而有之（灰色/混合模型）。过程和可靠性与维护必然会越来越相互作用，每一个单独的操作都会有相互的利益，但最重要的是，整个系统，整个工厂的利益。

这篇文章反映了我们的个人观点，基于我们在这个领域的经验，并仔细分析了多年来发表的丰富多样的技术文献。我们认为IPM检测，诊断和预后三个维度的正确整合将使这一活动对公司未来的运营更为有效和重要。

## 参考文献原文